



UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH

Escola Superior d'Enginyeries Industrial,
Aeroespacial i Audiovisual de Terrassa

Extrapolación de respuestas impulsionales de recintos acústicos usando aprendizaje profundo

Documento:

Trabajo Final de Grado

Autor:

Eduard Peñas Balart

Director:

Albino Nogueiras Rodríguez

Titulación:

Grado en Ingeniería de Sistemas Audiovisuales

Convocatoria:

Primavera de 2026

TREBALL DE FI D'ESTUDIS

Resum

La síntesi de respostes impulsional de sala (RIR) completes mitjançant simulació acústica convencional presenta un cost computacional elevat. Aquest treball parteix de la hipòtesi que la porció inicial d'una RIR (els primers 50 ms), que conté el so directe i les primeres reflexions, incorpora informació suficient sobre la geometria i les propietats acústiques del recinte per reconstruir-ne la reverberació tardana.

S'ha emprat DECOR (*Deep Exponential Completion Of Room impulse responses*), una arquitectura codificador-decodificador orientada a la completació de RIR. El codificador comprimeix la capçalera de la RIR (2400 mostres a 48 kHz) mitjançant nou blocs convolucional amb connexions *skip* i reducció progressiva de la resolució temporal, obtenint un vector latent de 128 dimensions. El decodificador, guiat per un model físic de soroll blanc amb decaïment exponencial, estima envoltants multiexponencials que modulen seqüències de soroll filtrat a través d'un banc de deu filtres FIR en bandes d'octava ISO 266. Aquesta formulació introdueix biaix acústic amb l'objectiu de reduir la mida del model preservant capacitat representacional.

L'eficàcia de la proposta s'ha validat mitjançant comparació amb una arquitectura d'estat de l'art de mida considerablement superior. Els resultats indiquen que DECOR assoleix un rendiment competitiu amb una complexitat substancialment menor, i confirmen la viabilitat de la completació de RIR com a estratègia pràctica per a l'extrapolació de reverberació tardana.

Resumen

La síntesis de respuestas impulsionales de sala (RIR) completas mediante simulación acústica convencional presenta un coste computacional elevado. Este trabajo parte de la hipótesis de que la porción inicial de una RIR (los primeros 50 ms), que contiene el sonido directo y las reflexiones tempranas, incorpora información suficiente sobre la geometría y las propiedades acústicas del recinto para reconstruir la reverberación tardía.

Se ha empleado DECOR (*Deep Exponential Completion Of Room impulse responses*), una arquitectura codificador-decodificador orientada a la completación de RIR. El codificador comprime la cabecera de la RIR (2400 muestras a 48 kHz) mediante nueve bloques convolucionales con conexiones *skip* y reducción progresiva de la resolución temporal, obteniendo un vector latente de 128 dimensiones. El decodificador, guiado por un modelo físico de ruido blanco con decaimiento exponencial, estima envolventes multiexponenciales que modulan secuencias de ruido filtrado a través de un banco de diez filtros FIR en bandas de octava ISO 266. Esta formulación introduce sesgo acústico con el objetivo de reducir el tamaño del modelo preservando capacidad representacional.

La eficacia de la propuesta se ha validado mediante comparación con una arquitectura del estado del arte de tamaño considerablemente superior. Los resultados indican que DECOR alcanza un rendimiento competitivo con una complejidad sustancialmente menor, y confirman la viabilidad de la completación de RIR como estrategia práctica para la extrapolación de reverberación tardía.

Abstract

Synthesizing complete room impulse responses (RIRs) through conventional acoustic simulation is computationally demanding. This work is based on the hypothesis that the initial segment of an RIR (the first 50 ms), which contains the direct sound and early reflections, carries sufficient information about room geometry and acoustic properties to reconstruct the late reverberation tail. DECOR (*Deep Exponential Completion Of Room impulse responses*) is implemented as an encoder-decoder architecture for RIR completion. The encoder compresses the RIR head (2400 samples at 48 kHz) through nine convolutional blocks with skip connections and progressive temporal downsampling, yielding a 128-dimensional latent vector. The decoder, informed by a physical model of exponentially decaying white noise, predicts multi-exponential decay envelopes that shape filtered-noise sequences through a bank of ten FIR filters in ISO 266 octave bands. This design introduces acoustic inductive bias to reduce model size while preserving expressive capacity. The effectiveness of the approach is validated against a significantly larger state-of-the-art baseline. Results show that DECOR reaches competitive performance with substantially lower complexity, supporting the practical viability of RIR completion for late-reverberation extrapolation.

Índice

Resum	ii
Resumen	iii
Abstract	iv
Lista de figuras	vi
Lista de tablas	vii
Abreviaturas	viii
1 Introducción	1
1.1 Objetivo	1
1.2 Impacto	2
1.3 Requisitos	2
2 Fundamentos Teóricos	4
2.1 Acústica de salas	4
2.1.1 Hipótesis y limitaciones del marco físico	7
2.1.2 Modelo de filtros	8
2.1.3 Modelos de aprendizaje	9
2.1.4 Trazabilidad entre teoría y evaluación	10
3 Estado de la cuestión	11
3.1 Acústica geométrica	11
3.1.1 Trazado de Rayos (<i>Ray Tracing</i>)	11
3.1.2 Método de Fuentes Imagen (ISM)	14
3.2 Aprendizaje profundo	15

3.2.1	PINNs: Physics-Informed Neural Networks	15
3.2.2	FiNS: Filtered Noise Shaping	16
3.2.3	DECOR	18
4	Diseño y Arquitectura del Modelo	21
4.1	Formulación	21
4.2	El Codificador	22
4.3	Decodificador	23
4.4	Pérdida	23
5	Marco Experimental y Datasets	25
5.1	Corpus BIRD	25
5.2	Dataset sintético	28
5.3	Pipeline EDC	29
5.4	Entrenamiento	30
6	Resultados y Discusión	34
6.1	Convergencia	34
6.2	Evaluación	36
6.3	Caso cualitativo	37
6.4	Análisis de Complejidad Computacional	40
7	Conclusiones y Trabajo Futuro	42
7.1	Conclusiones	42
7.2	Trabajo futuro	43
	Presupuesto y viabilidad económica	I
7.3	Costes	I
	Impacto ambiental y social	II
	Bibliography	IV

Lista de figuras

2.1 Partes de la RIR	5
2.2 Curvas de decaimiento global	9
3.1 Coste computacional del trazado de rayos	12
3.2 Rendimiento de almacenamiento según porcentaje de rayos	13
3.3 Distribución de energía acústica en trazado de rayos	13
3.4 Crecimiento cúbico en ISM	15
3.5 Extrapolación de RIR con PINNs	16
3.6 Arquitectura de FiNS	17
3.7 Concepto de <i>RIR completion</i>	18
3.8 Esquema general de la arquitectura DECOR	19
5.1 Configuración espacial BIRD	26
5.2 Preprocesado BIRD	27
5.3 Curva de Decaimiento de Energía (EDC)	30
6.1 Evolución de pérdidas	34
6.2 Convergencia EDC-L1	35
6.3 Norma del gradiente	36
6.4 Evaluación cualitativa	38

Lista de tablas

4.1	Dimensiones tensoriales de las variables principales del modelo DECOR.	22
6.1	Métricas de evaluación objetiva sobre el conjunto de test.	37
6.2	Comparativa de métricas	37
6.3	Comparativa de complejidad	41
7.1	Resumen de costes del TFG (estimación simple)	I

Lista de abreviaturas

RIR *Room Impulse Response* — Respuesta al Impulso de Sala.

EDC *Energy Decay Curve* — Curva de Decaimiento de Energía.

DECOR *Deep Exponential Completion Of Room impulse responses* — arquitectura propuesta para completación de RIR.

BIRD *Big Impulse Response Dataset* — corpus de respuestas impulsionales empleado en la validación.

ISM *Image Source Method* — Método de Fuentes Imagen para simulación acústica.

DDSP *Differentiable Digital Signal Processing* — Procesamiento Digital de Señal Diferenciable.

MSTFT *Multi-Resolution Short-Time Fourier Transform* — pérdida espectral multirresolución.

T₆₀ Tiempo de reverberación para un decaimiento de 60 dB.

DRR *Direct-to-Reverberant Ratio* — Relación Directo-Reverberante.

FIR *Finite Impulse Response* — filtro de respuesta al impulso finita.

HRTF *Head-Related Transfer Function* — función de transferencia relacionada con la cabeza.

GPU *Graphics Processing Unit* — unidad de procesamiento gráfico.

Capítulo 1

Introducción

1.1 Objetivo

El objeto central de este Trabajo de Fin de Grado consiste en el diseño, la implementación y la validación de un modelo de aprendizaje profundo capaz de ejecutar la extrapolación temporal de la reverberación tardía (*tail*) a partir de la observación de los primeros 50 ms (*head*) de la Respuesta al Impulso de la Sala (RIR) [LGS25]. Desde una perspectiva metodológica, el problema se formula como una tarea de predicción condicionada en la que la porción temprana de la respuesta contiene la información estructural necesaria para estimar la evolución energética y espectral de la cola reverberante.

El alcance del proyecto comprende el desarrollo de tuberías de datos reproducibles, la programación de los bloques neuronales del sistema propuesto y la evaluación del rendimiento mediante métricas analíticas acústicas. Quedan expresamente fuera del alcance las optimizaciones a nivel de firmware para ejecución en sistemas embebidos de bajo consumo, así como el procesamiento geométrico tridimensional multicanal.

La memoria se articula en siete capítulos. El Capítulo 1 introduce el problema, su motivación y los requerimientos técnicos. El Capítulo 2 establece los fundamentos teóricos. El Capítulo 3 presenta el estado de la cuestión. El Capítulo 4 desarrolla el diseño y la arquitectura del modelo DECOR. El Capítulo 5 describe el marco experimental y los conjuntos de datos. El Capítulo 6 analiza los resultados y su discusión crítica. Finalmente, el Capítulo 7 recoge las conclusiones y las líneas de trabajo futuro.

1.2 Impacto

La relevancia científica y tecnológica de esta investigación se enmarca en el crecimiento del audio inmersivo para Realidad Virtual (VR) y Realidad Aumentada (AR), ámbitos en los que la caracterización acústica del recinto condiciona de forma directa la plausibilidad perceptual de la escena sonora. Los métodos tradicionales de simulación, como el Método de Fuentes Imagen (ISM) o el trazado de rayos, presentan un coste computacional elevado que crece de manera muy acusada con la duración de la cola reverberante, lo que limita su uso en escenarios con exigencias temporales estrictas.

El impacto esperado se establece en tres dimensiones complementarias. En el plano técnico, se persigue una reducción drástica del tiempo de inferencia mediante un paradigma de procesamiento de señal diferenciable orientado a síntesis eficiente. En el plano acústico, se pretende preservar verosimilitud física al incorporar restricciones teóricas en el decodificador, de modo que la señal estimada respete patrones de decaimiento compatibles con la física del recinto. En el plano aplicado, el sistema presenta potencial de transferencia como herramienta de aumento de datos para sistemas de reconocimiento de voz, al permitir generar colas reverberantes plausibles en volumen elevado y coste operativo reducido.

1.3 Requisitos

Las especificaciones del sistema se formulan bajo criterios medibles y verificables, de acuerdo con principios de ingeniería de sistemas orientados a trazabilidad experimental y validación cuantitativa.

- **Requerimientos de Entrada/Salida de Señal**

- Procesamiento monoaural con frecuencia de muestreo estricta de 48 kHz.
- Ventana de entrada acotada a $N_{head} = 2400$ muestras.
- Horizonte de predicción de cola fijado en $N_{tail} = 45600$ muestras.

- **Requerimientos de Coherencia Acústica**

- Conservación de continuidad energética entre cabeza y cola sintetizada.
- Error absoluto medio (MAE) acotado sobre la curva EDC.
- Desajustes controlados en métricas físicas de referencia T_{60} y DRR.

- **Requerimientos del Ciclo de Entrenamiento**

- Estabilidad numérica absoluta, con ausencia de valores NaN o Inf.
- Repetibilidad experimental mediante fijación estricta de semillas pseudoaleatorias.
- Mecanismos automatizados de *checkpointing* basados en minimización de pérdida de validación.

- **Requerimientos de Ejecución y Cómputo**

- Adecuación de las rutinas de optimización masiva a entornos en la nube con GPU de alta gama.
- Tiempo de inferencia de la red predictiva varios órdenes de magnitud inferior al de un simulador físico geométrico convencional.

Capítulo 2

Fundamentos Teóricos

2.1 Acústica de salas

La Respuesta al Impulso de la Sala, denotada como $h(t)$, constituye una caracterización útil del comportamiento acústico de un recinto cuando este se aproxima como un sistema lineal e invariante en el tiempo (LTI). Aunque esta idealización no es estricta en cualquier situación real, resulta razonable cuando la geometría del espacio, la posición fuente-receptor y las condiciones ambientales se mantienen estables durante la medida. Bajo dicho marco, $h(t)$ representa la salida del sistema ante una excitación impulsiva ideal y encapsula tanto la propagación directa como los procesos de reflexión sobre fronteras materiales.

La respuesta temporal se descompone en tres contribuciones: sonido directo (*direct sound*), reflexiones tempranas (*early reflections*) y reverberación tardía (*late reverberation*). Esta partición no solo tiene interés descriptivo, sino también metodológico, ya que permite formular el problema de extrapolación de cola reverberante como una tarea condicionada por el contenido temprano.

En tiempo discreto, para una frecuencia de muestreo f_s , la señal registrada $y[n]$ se modela como la convolución entre una excitación $x[n]$ y la RIR del recinto:

$$y[n] = (x * h)[n] = \sum_{k=-\infty}^{\infty} x[k]h[n-k]. \quad (2.1)$$

La RIR discreta puede expresarse como

$$h[n] = h_{dir}[n] + h_{early}[n] + h_{late}[n], \quad (2.2)$$

donde $h_{dir}[n]$ concentra la llegada directa, $h_{early}[n]$ contiene reflexiones resolubles de bajo orden y $h_{late}[n]$ modela la contribución densa y predominantemente difusa del campo reverberante.




Figura 2.1: Partes de la Respuesta al Impulso de una sala: sonido directo, reflexiones tempranas y reverberación tardía.[Dzi+21]

El concepto de tiempo de mezcla, t_{mix} , establece el umbral físico a partir del cual la densidad temporal de reflexiones se vuelve suficientemente alta como para que el campo acústico transite hacia un régimen difuso y de naturaleza estocástica [Kut16]. Antes de dicho instante, las reflexiones mantienen una estructura temporal relativamente resoluble y conservan información geométrica macroscópica del recinto; después de t_{mix} , la superposición densa de trayectorias reduce la interpretabilidad determinista individual de cada reflexión.

Es importante remarcar que t_{mix} no es universal: depende del volumen, la geometría, el grado de difusión y la absorción del recinto. En consecuencia, salas pequeñas y más absorbentes tienden a presentar una transición temprana, mientras que salas grandes o menos absorbentes pueden desplazar ese umbral a tiempos mayores. En modelos como FINS y DECOR se adopta con frecuencia una frontera de 50 ms por su utilidad práctica y su buen compromiso experimental, pero debe interpretarse como una convención operativa, no como una constante física válida para cualquier sala [DP10].

Tomando $f_s = 48$ kHz, una ventana de 50 ms equivale a 2400 muestras. Esta equivalencia permite

fijar una frontera operativa entre parte temprana y parte tardía en el dominio discreto. En el planteamiento del trabajo, dicha frontera se usa como criterio práctico para definir entrada y objetivo del modelo: el segmento inicial contiene información geométrica y energética suficiente para condicionar la estimación de la cola reverberante posterior.

De forma general, la parte tardía suele modelarse de forma aproximada como un proceso aleatorio modulado por una envolvente exponencial decreciente. Esta hipótesis explica por qué la fase puntual de la cola es difícil de predecir de manera determinista, mientras que sus propiedades energéticas globales sí pueden modelarse de forma estable [DP10].

Dado que la reverberación tardía presenta un carácter estocástico, su análisis resulta más robusto cuando se formula en términos energéticos. En este contexto, se adopta la Curva de Decaimiento de Energía (EDC) según la formulación de Schroeder [Sch65]:

$$\text{EDC}(t) = \int_t^\infty h^2(\tau) d\tau, \quad (2.3)$$

lo que permite cuantificar la energía remanente de la respuesta al impulso a medida que avanza el tiempo. La representación en dB de la EDC facilita la estimación del tiempo de reverberación T_{60} , definido como el intervalo necesario para que la energía descienda 60 dB respecto al nivel inicial.

Su versión discreta, empleada en procesamiento digital, se define como

$$\text{EDC}[n] = \sum_{k=n}^{N-1} h^2[k], \quad (2.4)$$

y su forma normalizada en dB como

$$\text{EDC}_{dB}[n] = 10 \log_{10} \left(\frac{\text{EDC}[n]}{\text{EDC}[0]} \right). \quad (2.5)$$

La estimación de T_{60} suele realizarse mediante ajuste lineal sobre un tramo útil del decaimiento (por ejemplo, T20 o T30) y extrapolación posterior a 60 dB. Esta formulación reduce la sensibilidad al ruido de fondo y a irregularidades locales de la RIR.

Además de T_{60} , es conveniente considerar métricas complementarias para caracterizar la calidad física de la extrapolación. Entre ellas destacan la relación directo-reverberante (DRR) y, cuando procede, índices de claridad como C_{50} o C_{80} , que reflejan la distribución temporal de energía relevante para inteligibilidad y percepción espacial.

En recintos reales, la transición desde el régimen temprano hacia la reverberación tardía rara vez es perfectamente idealizada. Factores como la absorción frecuencial de los materiales, la dispersión de las superficies, la geometría del recinto y pequeñas variaciones en la temperatura o la humedad introducen desviaciones respecto al modelo LTI perfecto. [Kut16] No obstante, la aproximación LTI sigue siendo extremadamente útil porque permite describir la respuesta acústica con una función impulsional única y estable, suficientemente precisa para muchos fines de simulación y aprendizaje automático.

2.1.1 Hipótesis y limitaciones del marco físico

Para interpretar correctamente los resultados, es necesario explicitar las hipótesis adoptadas:

- Cuasi-invariancia temporal del recinto durante la adquisición y el uso del modelo. Esta hipótesis exige que la relación entrada-salida permanezca aproximadamente estable durante la medida, de modo que el sistema de aprendizaje pueda identificar regularidades consistentes. Si las condiciones del recinto cambiasen de forma continua, la RIR dejaría de representar un patrón estacionario y la capacidad de generalización del modelo se vería comprometida.
- Posiciones de fuente y receptor fijas para cada RIR. Una RIR está asociada a una configuración espacial concreta entre emisor y micrófono; pequeñas variaciones de posición modifican tiempos de llegada, interferencias y balance energético. Por ello, asumir geometría fija por muestra es clave para que la extrapolación de la cola sea físicamente coherente.
- Campo tardío aproximadamente difuso a partir de un umbral temporal de mezcla. Bajo esta hipótesis, la cola reverberante se describe mejor mediante propiedades estadísticas globales (por ejemplo, la EDC) que mediante la predicción determinista de cada reflexión individual. Si el campo tardío no presentara ese carácter difuso, la estructura fina de la fase y de las trayectorias sería más determinista y, en consecuencia, más difícil de inferir a partir del segmento temprano.
- Representatividad del contenido temprano para inferir propiedades estadísticas de la cola. Esta es la hipótesis central del trabajo: en la ventana inicial se asume codificada la información dominante sobre geometría, absorción y escala temporal del decaimiento. En términos prácticos, implica que el tramo temprano contiene suficientes pistas para estimar la dinámica energética de la parte tardía con precisión útil.

Estas hipótesis no siempre se cumplen de forma exacta en escenarios reales. Cambios dinámicos del entorno, ocupación variable, no linealidades de transductores o ruido de medida pueden degradar la

validez de la aproximación. Sin embargo, el marco sigue siendo adecuado como fundamento para aprendizaje supervisado orientado a extrapolación de reverberación tardía.

2.1.2 Modelo de filtros

Desde el punto de vista del procesamiento de señales, la RIR puede interpretarse como la respuesta impulsional de un sistema lineal que transforma una excitación sonora en una señal reverberante. Esta interpretación permite conectar la acústica de salas con herramientas clásicas como la convolución, las transformadas de Fourier y los bancos de filtros.

El modelo de filtrado supone que la señal observada puede descomponerse en contribuciones por bandas de frecuencia, cada una con un comportamiento de decaimiento diferente. Esta descomposición resulta especialmente apropiada para la reverberación tardía, donde las altas frecuencias tienden a disiparse antes que las bajas.

Sea $\{\mathcal{B}_b\}_{b=1}^B$ un banco de filtros y $h_b[n]$ la componente en la banda b . Entonces,

$$h[n] \approx \sum_{b=1}^B h_b[n], \quad (2.6)$$

con dinámicas de decaimiento potencialmente distintas para cada banda. En términos prácticos, esta formulación permite representar la cola reverberante como una combinación de envolventes energéticas y contenido espectral dependiente de frecuencia, lo cual es coherente con la física de absorción de materiales.

Esta perspectiva también justifica el uso de funciones de pérdida que no se limiten al error punto a punto en el dominio temporal, sino que incorporen estructura tiempo-frecuencia para preservar simultáneamente detalle local y tendencia global de decaimiento.




Figura 2.2: Curvas de decaimiento global calculadas para ocho bandas de octava. Los tiempos de reverberación derivados se enumeran en el cuadro de la derecha. Se observa que las frecuencias más altas presentan un decaimiento más rápido, lo cual es consistente con la absorción preferencial de materiales a frecuencias elevadas.[RC07]

2.1.3 Modelos de aprendizaje

El modelado de audio en bruto es complejo debido a la alta dimensionalidad de las señales temporales y a su sensibilidad a las variaciones de fase. Para abordar esto, en el aprendizaje profundo se emplean espacios latentes que actúan como representaciones comprimidas de las características esenciales de los datos [GBC16].

En este trabajo, el problema se formula como una inferencia condicional de cola reverberante a partir del segmento temprano:

$$p(\mathbf{h}_{tail} | \mathbf{h}_{head}). \quad (2.7)$$

La aproximación implementada es determinista y se expresa mediante una arquitectura codificador-decodificador, donde el codificador extrae una representación latente y el decodificador reconstruye la parte tardía estimada.

Bajo esta formulación, un codificador ($\mathcal{E}$) mapea la señal de entrada $\mathbf{x}$ a un espacio compacto de menor dimensión:

$$\mathbf{z} = \mathcal{E}(\mathbf{x}), \quad (2.8)$$

mientras que el decodificador ($\mathcal{D}$) se encarga de reconstruir la señal a partir de dicha representación:

$$\hat{\mathbf{y}} = \mathcal{D}(\mathbf{z}). \quad (2.9)$$

En la notación específica del problema,

$$\hat{\mathbf{h}}_{tail} = \mathcal{D}(\mathcal{E}(\mathbf{h}_{head})). \quad (2.10)$$

Este enfoque permite concentrar la información acústica más relevante, facilita la extrapolación temporal y reduce el coste computacional frente a estrategias puramente autorregresivas sobre señal completa.

La validación del modelo no debe depender de una única métrica. Es recomendable combinar criterios espectro-temporales y criterios físicos de decaimiento energético para asegurar que la cola sintetizada no solo se parezca a la referencia en forma de onda, sino que también respete parámetros acústicos coherentes desde el punto de vista físico.

2.1.4 Trazabilidad entre teoría y evaluación

La coherencia entre fundamentos y resultados se establece mediante una correspondencia explícita entre hipótesis físicas y métricas de evaluación:

- La hipótesis de estructura tiempo-frecuencia se contrasta con métricas espectrales de resolución múltiple.
- La hipótesis de decaimiento energético se valida con EDC y errores asociados a T_{60} .
- La relación entre energía directa y reverberante se verifica con DRR y magnitudes afines.

Esta trazabilidad evita interpretar el modelo de manera puramente numérica y permite analizar su comportamiento en términos acústicos, que es el objetivo final del problema de extrapolación.

Capítulo 3

Estado de la cuestión

La caracterización acústica de recintos mediante la Respuesta al Impulso de la Sala (RIR) es un desafío complejo que combina aspectos físicos, matemáticos y computacionales. Esta sección sitúa el estado de la cuestión desde los métodos geométricos clásicos (Ray Tracing e ISM), útiles para el análisis físico de salas, hasta los enfoques de aprendizaje profundo orientados a extrapolar la reverberación tardía con mayor eficiencia y capacidad de generalización.

3.1 Acústica geométrica para el análisis de salas y la síntesis de RIR

3.1.1 Trazado de Rayos (*Ray Tracing*)

Introducido en la acústica de salas a finales de la década de 1960 [KSS68], el trazado de rayos es un método estadístico que discretiza la energía acústica emitida por una fuente omnidireccional o direccional. El algoritmo emite un número finito de rayos que se propagan por el entorno virtual tridimensional. Cada vez que un rayo colisiona con un polígono, su energía disminuye en función del coeficiente de absorción del material, y se refleja de manera especular (siguiendo la ley de Snell) o se dispersa de manera difusa según el coeficiente de *scattering*. Para registrar la respuesta de impulso, se define un volumen de recepción (habitualmente esférico); cuando un rayo atraviesa este volumen, su energía, tiempo de llegada y dirección se acumulan en la Respuesta al Impulso de la Sala (RIR).

A pesar de ser el estándar en la industria para auralización, el trazado de rayos presenta limitaciones matemáticas y computacionales cuando se trata de sintetizar colas de reverberación densas y largas. Estudios sobre la optimización de motores de simulación geométrica, como la evaluación del entorno GSound-SIR [ZK25], han cuantificado empíricamente la ineficiencia de este método:

- **Escalabilidad lineal del coste computacional:** El tiempo de simulación y el procesamiento de rutas válidas crecen de manera estrictamente lineal respecto al número total de rayos emitidos [ZK25]. Para lograr una densidad suficiente en la reverberación tardía, se requiere proyectar millones de rayos, lo que satura los recursos de procesamiento e imposibilita su uso dinámico en tiempo real.




Figura 3.1: Relación entre el tiempo de cálculo computacional y el número total de rayos emitidos, categorizado por el porcentaje de rayos especulares. El escalado estrictamente lineal subraya la limitación del método para simulaciones de alta densidad acústica. [ZK25]

- **Sobrecarga por reflexiones especulares:** La validación de trayectorias físicas libres de obstrucciones entre la fuente y el oyente es computacionalmente costosa. Las configuraciones de simulación que exigen un mayor porcentaje de reflexión especular frente a la difusa incrementan exponencialmente el tiempo de cálculo [ZK25].




Figura 3.2: Relación entre el tiempo de escritura en disco (izquierda) y el tamaño del archivo resultante (derecha) en función del porcentaje de rayos de mayor energía procesados. Aprovechar la redundancia energética descartando la inmensa mayoría de rayos de baja energía permite un ahorro drástico en los costes de almacenamiento y lectura de la simulación. [ZK25]

- **Redundancia energética masiva:** El análisis de distribución de energía en simulaciones densas revela que el cálculo exhaustivo de rayos es extremadamente ineficiente. Las mediciones indican que apenas el 0,1% de los rayos capturan el 81,8% de la energía acústica total de la sala, y el 10% superior de los rayos modela el 99,6% de la energía [ZK25]. Esto demuestra que los métodos tradicionales invierten la inmensa mayoría de sus ciclos de reloj en trazar decenas de miles de reflexiones tardías que apenas aportan una fracción marginal a la reconstrucción energética de la RIR.




Figura 3.3: Distribución de energía acústica acumulada en función del porcentaje de rayos simulados. Se observa que el 10% de los rayos de mayor intensidad concentran el 99,6% de la energía total, evidenciando la redundancia del cálculo exhaustivo para la reverberación tardía. [ZK25]

Esta redundancia energética y el alto coste computacional asociado a la resolución espacial exhaustiva evidencian el límite tecnológico del *Ray Tracing*. Como sugieren los propios autores del estudio, la enorme concentración de energía en una fracción mínima de rayos abre la puerta a enfoques basados en aprendizaje profundo [ZK25]; específicamente, a modelos capaces de reconstruir y extrapolar la respuesta impulsional completa a partir de un conjunto reducido de rayos de alta energía, los cuales corresponden físicamente al campo directo y a las primeras reflexiones [ZK25].

3.1.2 Método de Fuentes Imagen (ISM)

El Método de Fuentes Imagen (*Image Source Method*, ISM) es una de las técnicas de acústica geométrica más rigurosas para el modelado de reflexiones especulares. Formalizado originalmente por Allen y Berkley en 1979 para recintos de geometría rectangular estricta [AB79], el algoritmo asume que las interacciones de las ondas sonoras con las superficies rígidas se comportan como reflexiones ópticas en espejos. Matemáticamente, cada reflexión se modela sustituyendo la superficie reflectante por una fuente acústica virtual, ubicada en la posición simétrica a la fuente real respecto al plano de la pared.

La RIR en el punto receptor se construye superponiendo la señal directa y las contribuciones retrasadas y atenuadas de todas las fuentes imagen iterativas. Si bien el ISM ofrece una exactitud temporal absoluta para las primeras reflexiones, su viabilidad colapsa rápidamente al incrementar el orden de reflexión necesario para modelar la reverberación tardía.

La extensión del algoritmo a recintos de topología arbitraria (poliedros), desarrollada por Borish en 1984 [Bor84], puso de manifiesto el verdadero cuello de botella de esta metodología: el coste computacional. A diferencia de las geometrías de caja, en geometrías complejas el algoritmo debe realizar costosas pruebas de intersección y validación de visibilidad para garantizar que la trayectoria desde cada fuente virtual hasta el receptor no está obstruida por otros planos del recinto [Bor84].

Este esfuerzo de cómputo se agrava drásticamente debido a la naturaleza matemática del propio método. En un espacio tridimensional, el número de fuentes virtuales generadas escala de forma **cúbica** ($O(N^3)$) con respecto al orden de reflexión N . Dado que la densidad de ecos en una sala real aumenta proporcionalmente al cuadrado del tiempo, simular los tramos finales de la curva de decaimiento de energía exige computar un volumen inasumible de fuentes imagen. Por tanto, mientras que el ISM es la herramienta ideal para extraer la firma geométrica inicial del recinto (los primeros milisegundos de la RIR), su crecimiento polinómico de orden tres lo descarta por completo como método autónomo para la síntesis completa de la reverberación.




Figura 3.4: Crecimiento del número de fuentes virtuales en el Método de Fuentes Imagen (ISM) en 3D en función del orden de reflexión N . La tendencia muestra un comportamiento polinómico dominante de orden cúbico, coherente con $\mathcal{O}(N^3)$.

3.2 Enfoques basados en Machine Learning

3.2.1 PINNs: Physics-Informed Neural Networks

Las redes neuronales informadas por la física (PINNs) constituyen un paradigma innovador para la predicción de respuestas impulsionales (RIR). A diferencia de los enfoques puramente basados en datos, las PINNs son redes neuronales entrenadas para resolver ecuaciones diferenciales parciales. En acústica de salas, esto implica incorporar la ecuación de onda en la función de pérdida mediante la diferenciación automática. Así, al combinar pocas mediciones con las ecuaciones de derivadas parciales que rigen la propagación del sonido, el modelo aprende la física del problema en lugar de mapear únicamente correlaciones estadísticas. Esto proporciona una representación continua libre de malla del campo sonoro, destacando en la reconstrucción precisa de los frentes de onda tempranos.

Matemáticamente, el entrenamiento de una PINN para la estimación de RIR se formaliza como la minimización de una función de pérdida que combina un término de error de datos (mediciones) y un término de error físico (residuo de la ecuación de onda) [Kar+24]:

$$\mathcal{L}(\theta) = \lambda_{\text{data}} \sum_{i=1}^N \left\| \hat{h}(t_i; \theta) - h_{\text{meas}}(t_i) \right\|^2 + \lambda_{\text{physics}} \int \left| \frac{\partial^2 \hat{h}}{\partial t^2} - c^2 \Delta \hat{h} \right|^2 dt \quad (3.1)$$

donde $\hat{h}(t; \theta)$ es la RIR predicha por la red con parámetros θ , $h_{\text{meas}}(t_i)$ son las mediciones de RIR

en tiempos discretos t_i , y c es la velocidad del sonido. Las constantes λ_{data} y λ_{physics} equilibran la importancia relativa de los términos de pérdida de datos y física.

Los resultados de [Kar+24] demuestran que las PINNs pueden extrapolar con precisión los frentes de onda tempranos a partir de un número limitado de mediciones, superando a métodos tradicionales como el ISM. Sin embargo, la síntesis completa de RIRs mediante PINNs sigue siendo un desafío debido a la complejidad de las ecuaciones de onda en entornos tridimensionales y a la necesidad de un entrenamiento intensivo para converger a soluciones estables.




Figura 3.5: Comparación de la reconstrucción de la RIR en términos de presión sonora a partir de un número limitado de mediciones. Se observa que la PINN logra reconstruir con precisión los frentes de onda tempranos, aunque la síntesis completa de la reverberación tardía sigue siendo un desafío. [Kar+24]

3.2.2 FiNS: Filtered Noise Shaping

En el ámbito de la estimación respuesta al impulso de la sala (RIR) a partir de voz reverberante, el modelo FiNS (Filtered Noise Shaping) [SIC21] propone un enfoque basado en el aprendizaje profundo para la estimación directa en el dominio del tiempo. Este método resulta útil para aplicaciones de realidad aumentada y posproducción de audio, donde se requiere un emparejamiento acústico preciso y de alta fidelidad operando a 48 kHz.

A diferencia de los enfoques que predicen parámetros para reverberadores algorítmicos o emplean modelos de transformación de gran tamaño, FiNS modela directamente la acústica del espacio basándose únicamente en una grabación de referencia. Esto permite reemplazar simulaciones complejas por una operación de convolución simple entre una señal de entrada y la RIR predicha.

Para lograr esto, la arquitectura de la red incorpora un fuerte sesgo inductivo inspirado en la acústica de salas, separando el modelado de la respuesta mediante un codificador y un decodificador especializados. El codificador en el dominio del tiempo procesa la señal de entrada utilizando bloques de convoluciones unidimensionales para capturar el comportamiento temporal a diferentes escalas, generando finalmente un espacio latente. Esta separación es clave porque, como ocurre de forma sistemática en acústica de recintos, la parte más difícil de predecir es el campo reverberante tardío: su carácter denso y estocástico, junto con la superposición de un gran número de reflexiones

débiles y sensibles a pequeñas variaciones geométricas y de absorción, incrementa notablemente la incertidumbre del modelo.




Figura 3.6: Esquema de la arquitectura de FiNS, destacando el codificador temporal y el decodificador especializado para modelar por separado la respuesta temprana (sonido directo y primeras reflexiones) y la reverberación tardía (cola reverberante).[SIC21]

En la arquitectura propuesta para la síntesis y estimación acústica, el modelo procesa una señal de entrada en el dominio del tiempo $x(n)$ mediante un codificador (*Encoder*) para extraer un vector de características en el espacio latente $\mathbf{z}$. A partir de esta representación, el decodificador (*Decoder*) divide la reconstrucción de la respuesta al impulso de la habitación en dos enfoques complementarios basados en la física del sonido.

Por un lado, estima de manera directa el sonido directo y las reflexiones tempranas, componente denotado como $h_d(n)$. Por otro lado, para modelar la reverberación tardía de naturaleza estocástica, el decodificador genera un conjunto de máscaras de ruido o envolventes temporales $y_1(n), \dots, y_m(n)$ (restringidas al rango de valores entre 0 y 1 mediante una función de activación sigmoide σ).

Simultáneamente, una señal de ruido blanco continuo $w(n)$ alimenta un banco de filtros convolucionales unidimensionales entrenable (*Learnable filterbank*), generando múltiples componentes de ruido en subbandas $s_1(n), \dots, s_m(n)$. Cada máscara de ruido proyectada por el decodificador modula en amplitud a su respectiva subbanda de ruido para emular el decaimiento exponencial característico de la energía acústica con el tiempo.

Finalmente, el conjunto de las subbandas moduladas por las envolventes y la componente inicial $h_d(n)$ se combinan e integran a través de una última capa convolucional de una dimensión (Conv1d) para producir la estimación completa y final de la respuesta al impulso de la habitación $\hat{h}(n)$.

El aspecto más destacable para la extrapolación acústica reside en el decodificador, el cual descompone la síntesis de la RIR modelando por separado la respuesta temprana y la cola reverberante.

Por un lado, la red utiliza un canal de salida dedicado para predecir directamente en el dominio del tiempo las muestras correspondientes al sonido directo y a las primeras reflexiones.

Por otro lado, la reverberación tardía se modela como una suma de señales de ruido filtrado en decaimiento. Para generar esta cola reverberante, el decodificador produce máscaras temporales que modulan un conjunto de señales de ruido procesadas por un banco de filtros aprendibles.

Esta estrategia de combinar la predicción directa para las componentes tempranas y un enfoque estocástico basado en la conformación de ruido para la parte tardía resulta muy efectiva.

Las evaluaciones demuestran que FiNS no solo es capaz de sintetizar RIRs que coinciden con los parámetros objetivos de la sala, como el tiempo de reverberación (T_{60}) y la relación directo-reverberante (DRR), sino que también reproduce las características perceptivas con mayor realismo y precisión que otras arquitecturas base de aprendizaje profundo [SIC21].

3.2.3 DECOR: Deep Exponential Completion Of Room Impulse Responses

El modelado preciso de la reverberación tardía resulta costoso computacionalmente, pero el sonido directo y las primeras reflexiones encapsulan información suficiente sobre la geometría de la sala y sus características de absorción. Para explotar esta relación, se ha formalizado la tarea de *RIR completion* (completado de la respuesta al impulso de la sala), cuyo objetivo es sintetizar la reverberación tardía a partir de la porción temprana (los primeros 50 ms) de la respuesta [LGS25].




Figura 3.7: Concepto de *RIR completion*: extrapolación de la reverberación tardía a partir del tramo temprano de la respuesta al impulso [LGS25].

Para abordar este problema, se han propuesto arquitecturas basadas en el paradigma codificador-decodificador (*encoder-decoder*). El modelo DECOR (*Deep Exponential Completion Of Room impulse responses*) es un exponente de esta tendencia [LGS25]. En este sistema, un codificador convolucional temporal profundo comprime la estructura de los primeros 50 ms en un vector latente de baja dimensión de 128 dimensiones. Posteriormente, un decodificador utiliza este vector para parametrizar un modelo físico de decaimiento exponencial [LGS25].




Figura 3.8: Esquema general de la arquitectura DECOR. El codificador procesa la cabeza de la RIR para generar un vector latente $\mathbf{z}$, que el decodificador utiliza para predecir envolventes de decaimiento aplicadas a un banco de filtros de ruido [LGS25].

DECOR se presenta como una evolución conceptual y estructural frente a arquitecturas previas como FiNS (*Filtered Noise Shaping*) [SIC21; LGS25]. FiNS fue diseñado originalmente para una tarea de estimación ciega, tomando fragmentos de varios segundos de voz reverberante para predecir la RIR [SIC21]. Aunque DECOR adapta la estructura del codificador de FiNS mediante convoluciones unidimensionales y conexiones residuales, la diferencia fundamental entre ambas redes radica en el diseño de su decodificador y en la imposición de un fuerte sesgo inductivo basado en la acústica de salas para la síntesis de la reverberación tardía [LGS25].

Mientras que el decodificador de FiNS utiliza un enfoque basado en sobremuestreo convolucional (*convolution upsampling*) [SIC21], DECOR modela estocásticamente la reverberación tardía como ruido blanco moldeado por una suma de envolventes de decaimiento exponencial [LGS25]. Específicamente, el decodificador de DECOR emplea un perceptrón multicapa (MLP) que toma el vector latente y predice matrices de amplitud temporal. Estas amplitudes se multiplican por tasas de decaimiento aprendibles (inicializadas para decaimientos T_{60} entre 0.05 y 3.0 segundos) para formar envolventes que modulan secuencias de ruido generadas por un banco de filtros de respuesta finita (FIR) en bandas de octava [LGS25].

Esta reformulación arquitectónica aporta ventajas significativas frente a FiNS que justifican su adopción para el completado de RIRs:

- **Eficiencia computacional y tamaño del modelo:** La parametrización física en el decodificador permite que DECOR sea extremadamente ligero. El modelo DECOR ocupa únicamente 37 MB, lo que lo hace más de 30 veces más pequeño que la arquitectura base de FiNS, cuyo peso asciende a 1,3 GB [LGS25]. Esta reducción drástica de parámetros facilita su despliegue en aplicaciones de síntesis en tiempo real para entornos dinámicos de realidad virtual o aumentada.
- **Eliminación de artefactos acústicos:** Las redes generativas que no imponen restricciones físicas estrictas sobre la síntesis de la señal suelen presentar problemas perceptuales. FiNS

tiende a generar picos dispersos de gran amplitud en la cola de la RIR, lo que introduce una "granulosidad" (*graininess*) poco natural en el audio resultante [SIC21; LGS25]. Al forzar a la red a predecir parámetros para un modelo de decaimiento exponencial puro, DECOR garantiza curvas de decaimiento suaves y un sonido más realista y coherente con el comportamiento acústico natural [LGS25].

- **Mejora en métricas objetivas:** DECOR supera a FiNS en la evaluación de la similitud con las características acústicas de la sala objetivo. Logra reducir el error en el dominio espectro-temporal (MSTFT), mejora la precisión de la función de decaimiento de energía (EDF), y estima con mayor exactitud tanto el tiempo de reverberación (T_{60}) como la relación directo-reverberante (DRR) [LGS25].
- **Capacidad de generalización:** Aunque la extrapolación de una señal a veinte veces su longitud original es una tarea compleja que penaliza a ambos modelos ante datos no vistos, DECOR mantiene un mejor rendimiento de generalización. Frente a conjuntos de datos de medición reales que la red no ha observado durante el entrenamiento, DECOR sigue siendo capaz de deducir relaciones correctas del T_{60} y superar a FiNS, demostrando que su arquitectura de decaimiento estructurado es más robusta frente a escenarios acústicos fuera de distribución [LGS25].

En conclusión, la transición de un enfoque de sobremuestreo genérico a un modelo fuertemente condicionado por la física acústica permite que DECOR resuelva el problema del *RIR completion* de forma mucho más eficiente. La parametrización directa de variables como el decaimiento por bandas de octava no solo elimina la inestabilidad de las muestras individuales, sino que dota a la red de una alta expresividad para modelar escenarios acústicos complejos manteniendo una huella computacional mínima. Por este motivo, DECOR constituye el método seleccionado para ser implementado y empleado en el desarrollo de este trabajo.

Capítulo 4

Diseño y Arquitectura del Modelo

Este capítulo presenta la formulación matemática y el diseño arquitectónico del modelo DECOR [LGS25], concebido como una solución eficiente para la extrapolación de respuestas al impulso de recinto a partir de observaciones parciales de corta duración.

4.1 Formulación

La señal acústica continua se discretiza a frecuencia de muestreo $f_s = 48$ kHz, obteniéndose la secuencia temporal discreta $h[n]$. El problema de completación de RIR se formula bajo el supuesto de observación parcial del tramo temprano de la respuesta. En particular, se define un índice de truncamiento fijo $N_{head} = 2400$ muestras, correspondiente a una ventana temporal de 50 ms.

Bajo esta partición, el vector de entrada se define como $\mathbf{x} \in \mathbb{R}^{2400}$, conteniendo el sonido directo y las reflexiones tempranas. El objetivo supervisado se define como el vector de cola reverberante $\mathbf{y} \in \mathbb{R}^{45600}$, asociado a los 950 ms restantes de la respuesta discreta.

El sistema DECOR se modela como un mapeo parametrizado $\mathcal{F}_\Theta : \mathbb{R}^{2400} \rightarrow \mathbb{R}^{45600}$, donde Θ denota el conjunto de parámetros entrenables. Su estructura interna se descompone en un codificador $\mathcal{E}_\psi$ y un decodificador $\mathcal{D}_\phi$:

$$\mathbf{z} = \mathcal{E}_\psi(\mathbf{x}), \quad \hat{\mathbf{y}} = \mathcal{D}_\phi(\mathbf{z}) = \mathcal{D}_\phi(\mathcal{E}_\psi(\mathbf{x})), \quad \Theta = \{\psi, \phi\}. \quad (4.1)$$

Tabla 4.1: Dimensiones tensoriales de las variables principales del modelo DECOR.

Componente	Símbolo Matemático	Dimensionalidad Tensorial
Cabeza de la RIR (Entrada)	$\mathbf{x}$	(1×2400)
Vector Latente	$\mathbf{z}$	(1×128)
Cola Sintetizada (Salida)	$\hat{\mathbf{y}}$	(1×45600)

4.2 El Codificador

La unidad elemental del codificador corresponde a un bloque convolucional residual. Para una entrada $\mathbf{h}_{in}$, la salida del bloque se define como

$$\mathbf{h}_{out} = \sigma(\mathcal{F}_{main}(\mathbf{h}_{in}) + \mathcal{F}_{skip}(\mathbf{h}_{in})). \quad (4.2)$$

En esta expresión, $\mathcal{F}_{main}$ denota una convolución unidimensional con tamaño de núcleo 15, salto 2 y relleno simétrico orientado a conservar coherencia dimensional local, seguida de normalización por lotes (*Batch Normalization*). Por su parte, $\mathcal{F}_{skip}$ representa la rama residual con convolución 1×1 y el mismo salto, con el fin de alinear la dimensionalidad de los tensores antes de la suma elemento a elemento. La no linealidad σ se implementa mediante una activación Parametric ReLU (PReLU).

La arquitectura completa de *DecorEncoder* se organiza como una cascada de 9 bloques residuales. La jerarquía de canales sigue la progresión

$$1 \rightarrow 16 \rightarrow 32 \rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 512 \rightarrow 512 \rightarrow 512 \rightarrow 512. \quad (4.3)$$

La aplicación sucesiva de salto 2 en cada bloque produce un factor de reducción temporal global igual a $2^9 = 512$. En consecuencia, la entrada original $\mathbf{x} \in \mathbb{R}^{1 \times 2400}$ experimenta una compresión pronunciada sobre el eje temporal, mientras la información acústica se redistribuye en la profundidad de los mapas de características.

Tras el último bloque convolucional, la salida se somete a una agrupación promedio global adaptativa (*Adaptive Average Pooling*), operación que colapsa la dimensión temporal residual y entrega un vector denso de 512 componentes. Finalmente, una transformación lineal proyecta dicho vector al embedding latente

$$\mathbf{z} \in \mathbb{R}^{128}, \quad (4.4)$$

el cual recoge la firma acústica de las reflexiones tempranas en una representación compacta apta para la etapa de síntesis de cola reverberante.

4.3 Decodificador

La síntesis de la cola reverberante estimada se rige por el siguiente modelo físico:

$$\hat{r}(t) = \sum_{m=1}^M \left(\sum_{k=1}^K A_{m,k} \cdot e^{-b_k(t_0+t)} \right) w_m(t) \quad (4.5)$$

donde $M = 10$ denota el número de bandas de octava bajo la norma ISO 266, $K = 20$ el número de tasas de decaimiento linealmente combinadas, $t_0 = 0.05$ s el instante de transición temporal correspondiente al inicio de la cola, y $w_m(t)$ el ruido blanco gaussiano filtrado asociado a la banda espectral m .

El estimador paramétrico inicial opera sobre el vector latente $\mathbf{z} \in \mathbb{R}^{128}$ mediante un perceptrón multicapa compuesto por 7 capas densas encadenadas, cada una con 512 unidades y activación LeakyReLU con pendiente de zona muerta $\alpha = 0.2$. La etapa de salida adopta un esquema ramificado (*multi-head*): una rama produce amplitudes base $A'_{m,k}$ y la otra produce coeficientes de enmascaramiento $C'_{m,k}$. La activación efectiva se obtiene por producto de Hadamard, con enmascaramiento sigmoideal, según $A_{m,k} = A'_{m,k} \odot \sigma(C'_{m,k})$.

Las tasas de amortiguamiento b_k se establecen sobre una escala log-uniforme vinculada a tiempos de reverberación T_{60} dentro del intervalo físico $[0.05, 3.0]$ s. Este criterio impone una restricción acústica inicial coherente con recintos reales y, al mismo tiempo, conserva flexibilidad, puesto que los b_k se tratan como parámetros libres optimizables durante el aprendizaje del modelo.

La etapa de coloración espectral utiliza un banco de 10 filtros FIR de fase lineal y orden 1023, calculados de forma analítica mediante diseño por ventanas con la función `firwin` de SciPy. Dicho banco separa la señal estocástica en bandas de octava normalizadas. Finalmente, una convolución unidimensional de tamaño de núcleo 1 recibe los 10 canales filtrados y ejecuta una suma ponderada optimizable, equivalente a una transformación lineal 1×1 , para reducir la representación multibanda a un único canal mono que constituye la cola extendida final.

4.4 Pérdida

La optimización directa sobre la forma de onda mediante Error Cuadrático Medio (MSE) resulta subóptima en tareas de síntesis de audio reverberante. En particular, el MSE presenta elevada

sensibilidad ante desajustes de fase que pueden ser perceptualmente poco relevantes, y no representa con fidelidad la respuesta auditiva humana, que depende de la distribución espectral de energía en el tiempo con mayor peso que del error puntual muestra a muestra.

Con el objetivo de ajustar el aprendizaje a criterios más cercanos a la percepción, se establece la pérdida de Transformada de Fourier a Corto Plazo multirresolución (MSTFT). Para una respuesta predicha $\hat{h}$ y una respuesta de referencia h , la pérdida total se define como

$$\mathcal{L}_{\text{MSTFT}}(\hat{h}, h) = \sum_{r=1}^R \left(L_{sc}^{(r)} + L_{sm}^{(r)} \right). \quad (4.6)$$

El término de convergencia espectral en la resolución r se expresa mediante norma de Frobenius como

$$L_{sc}^{(r)} = \frac{\left\| \left| \text{STFT}_r(\hat{h}) \right| - \left| \text{STFT}_r(h) \right| \right\|_F}{\left\| \left| \text{STFT}_r(h) \right| \right\|_F + \epsilon}. \quad (4.7)$$

El término de log-magnitud espectral se formula como

$$L_{sm}^{(r)} = \left\| \log \left(\left| \text{STFT}_r(\hat{h}) \right| + \epsilon \right) - \log \left(\left| \text{STFT}_r(h) \right| + \epsilon \right) \right\|_1. \quad (4.8)$$

En estas expresiones, ϵ es un término de estabilidad numérica. La presencia del logaritmo en $L_{sm}^{(r)}$ aproxima la sensibilidad psicoacústica a variaciones relativas de presión sonora, lo que favorece un ajuste más coherente con la percepción auditiva.

En el modelo presentado se emplean $R = 4$ resoluciones, con ventanas de Hann de tamaños $W \in \{64, 512, 2048, 8192\}$ y saltos proporcionales $H \in \{32, 256, 1024, 4096\}$. Esta selección combina escalas temporales cortas, adecuadas para transitorios rápidos, con escalas largas que mejoran la precisión frecuencial en el modelado de modos estacionarios y del decaimiento macroscópico de la reverberación tardía.

Capítulo 5

Marco Experimental y Datasets

Este capítulo expone el marco metodológico y experimental para la aplicación y evaluación de la arquitectura propuesta. En primer lugar, se describen los conjuntos de datos empleados como base de aprendizaje del modelo, detallando tanto el preprocesamiento del corpus masivo BIRD como la generación de un conjunto de datos sintético complementario. A continuación, se define la cadena de procesamiento de la señal, centrada en el cálculo de la Curva de Decaimiento de Energía (EDC) para el correcto acondicionamiento y análisis de las respuestas acústicas. Finalmente, se detalla la fase de entrenamiento, estableciendo las estrategias de optimización y los criterios de evaluación que permiten cuantificar el rendimiento y la capacidad de generalización de la red neuronal.

5.1 Corpus BIRD

El *Big Impulse Response Dataset* (BIRD) [Gro+20] constituye la fuente principal de datos empleada en este trabajo para el entrenamiento y validación de la arquitectura DECOR. En su concepción original, este conjunto de datos se define como el mayor corpus abierto de respuestas al impulso en salas multicanal, compuesto por un total de 100.000 RIRs simuladas mediante el Método de la Imagen (*Image Method*). Sin embargo, para los experimentos desarrollados en esta investigación, se ha seleccionado un subconjunto representativo de 40.000 respuestas. Esta dimensión muestral mantiene una base estadística suficientemente robusta para el entrenamiento de la red neuronal, a la vez que optimiza el coste computacional y los tiempos de iteración del modelo.

El uso de este corpus presenta ventajas sustanciales para la tarea que nos ocupa. Cada simulación varía aleatoriamente parámetros clave como las dimensiones físicas de la sala, la velocidad del sonido y las posiciones relativas de 2 micrófonos y 4 fuentes de sonido omnidireccionales. Dado que el coste computacional espacial del Método de la Imagen escala de forma cúbica en el espacio

tridimensional, disponer de un corpus precalculado de esta magnitud resulta fundamental para agilizar la experimentación.




Figura 5.1: Configuración espacial empleada para las simulaciones del corpus BIRD. El entorno virtual consiste en una sala rectangular de dimensiones $L_x \times L_y \times L_z$ metros, en la que se posicionan de manera aleatoria cuatro fuentes de sonido omnidireccionales (s_1, s_2, s_3, s_4) y un par de micrófonos (m_1, m_2) separados por una distancia d [Gro+20].

No obstante, la utilización de BIRD para la extrapolación de la cola reverberante conlleva limitaciones inherentes a su naturaleza sintética que es crucial documentar. La topología del corpus representa una abstracción espacial simplificada: el algoritmo de simulación genera exclusivamente habitaciones vacías estrictamente rectangulares. De igual modo, el modelado acústico asume un único coeficiente de absorción (α) idéntico para todas las superficies (suelo, techo y paredes) dentro de una misma sala.

Esta simplificación ignora la heterogeneidad de materiales presentes en entornos reales, lo que limita la variabilidad frecuencial y direccional de las reflexiones tardías que la red debe aprender a completar. Desde el punto de vista operativo, los archivos de audio originales—generados a una frecuencia de muestreo nativa de 16 kHz y con 1 segundo exacto de duración (16.000 muestras)—son sometidos a una secuencia estricta de adecuación previa a su paso por la red neuronal.

En primer lugar, cada señal multicanal se transforma a formato monoaural y se remuestrea a una frecuencia uniforme de 48 kHz, garantizando así la compatibilidad dimensional con la arquitectura DECOR. Sobre esta nueva base temporal, la respuesta se normaliza en amplitud y se alinea con respecto a su pico máximo para asegurar que el transitorio del sonido directo ocupe un índice determinista. Finalmente, la secuencia se ajusta a una longitud fija de 48.000 muestras (equivalentes a 1 segundo exacto).

Una vez acondicionada la señal, se procede a su segmentación en dos regiones de interés. Aprovechando la resolución obtenida tras el remuestreo, se aísla una cabeza temprana de longitud $N_{head} = 2400$ muestras (correspondientes exactamente a los primeros 50 ms), la cual abarca el sonido directo y las reflexiones tempranas. El resto de la secuencia conforma la cola reverberante remanente, que constituye el proceso de decaimiento tardío que el sistema debe aprender a extrapolar.




Figura 5.2: Efecto de la etapa de preprocesado sobre una respuesta al impulso del corpus BIRD. El procedimiento ilustrado incluye la extracción de un canal monoaural aleatorio, el sobremuestreo a 48 kHz y la alineación temporal basada en la detección de inicio (*onset detection*). Este método elimina el tiempo de vuelo originado en la simulación preservando la integridad morfológica del sonido directo y de las reflexiones tempranas previas al pico de máxima amplitud.

Finalmente, para prevenir la contaminación cruzada y el solapamiento acústico, la división del subconjunto de 40.000 respuestas impulsionales entre las fases de entrenamiento y validación no se efectúa de manera aleatoria a nivel de impulso individual, sino aprovechando la estructura de bloques independientes (*folds*) del corpus original. Al establecer la separación mediante estas agrupaciones de salas no solapadas, se garantiza que la evaluación se lleve a cabo sobre recintos acústicos no observados durante el ajuste de pesos, lo que proporciona una estimación rigurosa y fiable de la capacidad de generalización del modelo.

En resumen, el corpus BIRD ofrece un entorno de simulación controlado y de gran escala para el entrenamiento de modelos de aprendizaje profundo en tareas de extrapolación temporal de RIR. Sin embargo, su naturaleza sintética y sus simplificaciones acústicas introducen limitaciones que

deben ser consideradas al interpretar los resultados y extrapolar las conclusiones hacia escenarios del mundo real.

5.2 Dataset sintético

Con objeto de disponer de un entorno de control plenamente trazable, se generó un corpus sintético propio compuesto por 6000 recintos rectangulares. Este subconjunto no pretende sustituir la diversidad geométrica y material del corpus principal, sino proporcionar un banco de simulación pura en el que todas las variables relevantes quedan explícitamente determinadas. Tal circunstancia resulta especialmente valiosa para estudios de ablación y para la verificación de la consistencia física de la tubería de datos antes del inicio de las rutinas de aprendizaje.

La obtención de las respuestas impulsionales sintéticas se apoya en el Método de Fuentes Imagen (ISM), según la formulación clásica de [AB79], mediante su implementación en el entorno de código abierto *Pyroomacoustics*. Bajo este marco, las dimensiones tridimensionales del recinto, las coordenadas de la fuente acústica y del receptor, así como los coeficientes de absorción de las superficies, se determinan por muestreo aleatorio dentro de intervalos físicamente realistas. De esta manera, se obtiene un conjunto amplio de escenas acústicas artificiales con control explícito de sus parámetros geométricos y materiales.

La tubería operativa programada en el script `scripts/generate_synthetic_rir_dataset.py` produce y almacena, para cada muestra, cuatro artefactos en formato binario `.npy`: la RIR completa, la sección de cabeza correspondiente a los primeros 50 ms, la sección de cola asociada a los 950 ms restantes y la curva EDC derivada de dicha cola. De forma complementaria, las propiedades macroscópicas y los descriptores globales de cada recinto, entre ellos las dimensiones geométricas y el T_{60} estimado, se recogen de manera centralizada en un archivo tabular indexado denominado `metadata.csv`.

El control de calidad del conjunto sintético se lleva a cabo mediante el script `scripts/validate_generated_dataset.py`, cuya función consiste en actuar como filtro de sanidad analítica previo al entrenamiento. Esta rutina audita de forma sistemática los rangos geométricos admisibles, la coherencia espacial de las trayectorias fuente-receptor y la validez física del tiempo de reverberación calculado. Mediante este procedimiento se favorece la exclusión temprana de anomalías numéricas, artefactos de simulación o muestras incompatibles con los supuestos acústicos del problema.

5.3 Pipeline EDC

Dentro del flujo de procesamiento de datos, el cálculo de la Curva de Decaimiento de Energía (EDC, por sus siglas en inglés) se establece como métrica fundamental para evaluar la coherencia del decaimiento reverberante. Dado que la respuesta al impulso tardía presenta un comportamiento altamente estocástico, resulta inviable predecir su forma de onda exacta. Por ello, la EDC permite extraer una envolvente energética determinista que el modelo sí puede aprender a extrapolar. Para una secuencia discreta de la cola reverberante $y[n]$ de longitud N , se emplea la forma de integración discreta propuesta originalmente por Schroeder [Sch65]:

$$\text{EDC}_{\text{norm}}[t] = \frac{\sum_{n=t}^{N-1} y[n]^2}{\sum_{n=0}^{N-1} y[n]^2} \quad (5.1)$$

En esta formulación, la EDC se normaliza por la energía total de la cola para garantizar que su valor inicial sea exactamente 1 (0 dB) y que tienda asintóticamente a 0 a medida que el tiempo avanza. Esta normalización es crucial para establecer una escala de análisis coherente y para facilitar la comparación entre diferentes muestras con niveles de energía variables. donde $y[n]$ representa la secuencia discreta de la cola reverberante. Esta normalización garantiza una trayectoria monótona decreciente acotada en el intervalo $[0, 1]$, con valor unitario al inicio del decaimiento y aproximación asintótica a cero para tiempos tardíos.

Con el fin de obtener una escala de análisis perceptualmente adecuada, la curva normalizada se expresa en decibelios mediante transformación logarítmica:

$$\text{EDC}_{dB}[t] = 10 \log_{10} (\max(\text{EDC}_{\text{norm}}[t], \epsilon)) \quad (5.2)$$

El término de protección ϵ , asociado en práctica a un suelo dinámico del orden de -80 dB, resulta indispensable para preservar estabilidad numérica en el cálculo tensorial, evitando singularidades cuando la energía remanente tiende a cero.

Desde la perspectiva computacional, la lógica de segmentación temporal (corte exacto en la muestra 2400) y el cálculo de la EDC se implementan dentro de estructuras de carga iterativa (*DataLoaders*). Esto permite generar tensores de manera dinámica y empaquetarlos en lotes (*batches*), manteniendo un flujo de memoria estable hacia GPU sin colapso de memoria principal. De forma simultánea, se conserva la trazabilidad exacta entre la cabeza de entrada, la cola objetivo y su EDC analítica en cada muestra procesada.




Figura 5.3: Comparativa visual entre la forma de onda estocástica de una cola reverberante y su correspondiente Curva de Decaimiento de Energía (EDC) expresada en decibelios. Se observa cómo la integración de Schroeder extrae una envolvente energética determinista y monótonamente decreciente, transformando la señal bruta en un objetivo de aprendizaje estable para el modelo predictivo.

5.4 Entrenamiento

La fase de entrenamiento de la red neuronal se llevó a cabo utilizando el entorno basado en la nube Google Colab Pro, haciendo uso de una GPU NVIDIA A100. Las prestaciones de esta unidad de procesamiento gráfico resultan plenamente adecuadas para satisfacer la demanda computacional del modelo, permitiendo gestionar de manera eficiente las secuencias temporales inherentes al procesamiento de audio. La adopción de esta infraestructura basada en la nube destaca por ofrecer acceso inmediato a *hardware* de alto rendimiento sin requerir una elevada inversión en equipamiento local. No obstante, este entorno introduce limitaciones operativas significativas, tales como la interrupción forzosa de las sesiones por límites de tiempo y la dependencia de sistemas de almacenamiento no persistentes. En consecuencia, el uso de esta plataforma exigió la implementación de rutinas de guardado periódico (*checkpoints*) para salvaguardar los pesos de la red y mitigar la volatilidad del sistema.

Para garantizar la solidez de la evaluación ante datos no observados, se adoptó una estrategia de validación cruzada (*k-fold cross-validation*). El corpus se dividió manteniendo una proporción estricta de 3 *folds* dedicados a la fase de aprendizaje por cada *fold* reservado para la evaluación del rendimiento. Esta metodología asegura que el modelo se ajuste a una variedad de escenarios acústicos durante el entrenamiento, mientras que la validación se realiza sobre recintos completamente nuevos, lo que proporciona una estimación rigurosa de la capacidad de generalización del sistema.

Por otro lado, para dirigir el aprendizaje del modelo hacia una solución que sea tanto acústicamente precisa como físicamente coherente, la dinámica de ajuste de parámetros no puede depender de un único criterio. En su lugar, se rige por una función de coste compuesta que equilibra la fidelidad espectral y el comportamiento temporal del sonido:

$$\mathcal{L}_{total} = \beta \cdot \mathcal{L}_{MSTFT} + \alpha \cdot \mathcal{L}_{EDC-L1} \quad (5.3)$$

Esta formulación combina el error espectral multiresolución, ponderado por β , con el error absoluto asociado a la curva de decaimiento energético temporal, ponderado por α . Dentro del protocolo de validación, la métrica $L1$ sobre la EDC se establece como indicador principal para verificar la precisión física de la respuesta sintetizada durante el ciclo iterativo de aprendizaje.

Por último, la actualización de pesos se emplea con **Ranger21**, un optimizador diseñado para ejecutar trayectorias de aprendizaje prolongadas de forma robusta. Su elección se justifica por la incorporación de mecanismos de estabilización fundamentales para este tipo de modelado:

- **Recorte de gradientes (*Gradient Clipping*):** Permite mitigar el riesgo de explosión de gradientes, una inestabilidad característica cuando se trabaja en la predicción de secuencias largas.
- **Fase de enfriamiento (*Cooldown*):** Consiste en una reducción progresiva de la tasa de aprendizaje durante las últimas épocas del entrenamiento, lo que favorece una aproximación estable hacia mínimos más profundos en la superficie de coste.

El protocolo de entrenamiento se estructura en tres fases claramente diferenciadas:

1. **Fase 1 (Épocas 1 a 20) — Inicialización Frecuencial.** El entrenamiento se inició con un tamaño de lote de 128 muestras y una tasa de aprendizaje de $1 \cdot 10^{-4}$. En esta etapa se establecieron los pesos de la función de coste como $\alpha = 0.0$ y $\beta = 1.0$. El propósito consistió en permitir que la red asimilara la estructura espectral de la cola reverberante sin imponer todavía penalización temporal explícita, favoreciendo un asentamiento inicial de los parámetros del decodificador. Al cierre de esta fase se obtuvo una pérdida de validación (Val Loss) de 11.13 y un error EDC-L1 preliminar de 0.10.

Listing 5.1: Ejecución de entrenamiento correspondiente a la Fase 1.

```
DATA_LOCAL="/content/BIRD_Local"
CHECKPOINT_DRIVE="/content/drive/MyDrive/BIRD_Dataset/decor_best_model.pth"
```

```
!python scripts/train.py \  
    --data-root "$DATA_LOCAL" \  
    --epochs 20 \  
    --batch-size 128 \  
    --lr 1e-4 \  
    --num-workers 8 \  
    --checkpoint "$CHECKPOINT_DRIVE"
```

2. **Fase 2 (Épocas 21 a 400) — Estabilización Transitoria y Acoplamiento Físico.** La transición hacia la optimización conjunta mostró una inestabilidad intensa cuando se activó de forma abrupta la penalización temporal con $\alpha = 0.1$, observándose explosión de la norma del gradiente y aumento de la pérdida por encima de 19. Para mitigar este comportamiento se aplicó una estrategia progresiva: la tasa de aprendizaje se redujo a $1 \cdot 10^{-5}$ y el término temporal se suavizó inicialmente a $\alpha = 0.01$, elevándolo de manera gradual hasta 0.05. De forma complementaria, el tamaño de lote se amplió a 256 muestras para aprovechar la capacidad de cómputo de los aceleradores gráficos y disminuir la varianza estocástica del gradiente. Bajo este esquema el optimizador absorbió la nueva restricción y, en la época 390, se superó la barrera de pérdida con una Val Loss de 9.41 y un error EDC-L1 de 0.085.

Listing 5.2: Ejecución de entrenamiento correspondiente a la Fase 2.

```
!python scripts/train.py \  
    --data-root "$DATA_LOCAL" \  
    --epochs 400 \  
    --batch-size 256 \  
    --lr 1e-4 \  
    --loss-alpha 0.05 \  
    --loss-beta 1.0 \  
    --num-workers 8 \  
    --resume "$CHECKPOINT_PREVIO" \  
    --checkpoint "$NUEVO_CHECKPOINT"
```

3. **Fase 3 (Épocas 401 a 590) — Afinación Fina y Convergencia Asintótica.** En la etapa final se mantuvieron fijos el tamaño de lote en 256 y el peso temporal en $\alpha = 0.05$, operando con una tasa de aprendizaje conservadora de $1 \cdot 10^{-5}$ para recorrer el entorno del mínimo con mayor precisión. La fase de enfriamiento (*Cooldown*) de Ranger21 resultó determinante en este tramo, promoviendo el asentamiento definitivo de los pesos y una convergencia estable. En la iteración terminal se extrajo el punto de control óptimo (*checkpoint*), registrándose

un mínimo absoluto histórico con Val Loss de 9.345, resultado que respalda la eficacia del protocolo de entrenamiento.

Listing 5.3: Ejecución de entrenamiento correspondiente a la Fase 3 (pulido final).

```
!python scripts/train.py \  
    --data-root "$DATA_LOCAL" \  
    --epochs 590 \  
    --batch-size 256 \  
    --lr 1e-5 \  
    --loss-alpha 0.05 \  
    --loss-beta 1.0 \  
    --num-workers 8 \  
    --resume "$CHECKPOINT_PREVIO" \  
    --checkpoint "$NUEVO_CHECKPOINT"
```

Capítulo 6

Resultados y Discusión

6.1 Convergencia

El proceso de optimización se extendió a lo largo de 590 épocas, observándose un régimen de estabilización asintótica en el tramo final. La evolución de la función de coste compuesta (MSTFT + EDC) muestra un descenso sostenido y coherente entre entrenamiento y validación. Tal como se aprecia en la Figura 6.1, la curva de validación sigue de manera estrecha la trayectoria de entrenamiento y se mantiene en valores equivalentes o inferiores, alcanzando niveles en el entorno de 9.42. Este patrón descarta de forma consistente la presencia de sobreajuste (*overfitting*) y respalda la capacidad de generalización del modelo ante recintos no observados. Las oscilaciones de alta frecuencia, visibles tras superponer una tendencia suavizada por media móvil, se interpretan como un efecto inherente a la sensibilidad paramétrica de arquitecturas de Procesamiento Digital de Señal Diferenciable (DDSP).




Figura 6.1: Evolución de la pérdida compuesta de entrenamiento y validación. Se superpone la tendencia suavizada mediante media móvil.

La métrica física principal, definida como error absoluto medio sobre la Curva de Decaimiento

de Energía (EDC-L1), presenta convergencia robusta durante el entrenamiento. En particular, la trayectoria perfora el umbral de 0.10 y se consolida en torno a 0.08 en las épocas finales, tal como se observa en la Figura 6.2. Este comportamiento confirma que la red no solo reduce error espectral, sino que también preserva la dinámica energética del decaimiento reverberante con precisión físicamente consistente.




Figura 6.2: Convergencia del error absoluto medio de la Curva de Decaimiento de Energía (EDC-L1).

Desde la perspectiva de estabilidad numérica, la predicción de tasas de decaimiento exponencial b_k en el decodificador induce una superficie de pérdida fuertemente no convexa. La monitorización de la norma del gradiente, representada en la Figura 6.3, evidencia picos transitorios severos que superan magnitudes del orden de 10^4 . Esta observación empírica justifica con rigor la necesidad técnica de emplear recorte de gradientes (*gradient clipping*) dentro de Ranger21, mecanismo que resultó determinante para absorber inestabilidades locales y prevenir colapso numérico en los tensores durante fases críticas del aprendizaje.




Figura 6.3: Evolución de la norma del gradiente en escala logarítmica durante el entrenamiento.

6.2 Evaluación

La validación cuantitativa del sistema se ha llevado a cabo sobre el subconjunto de test, compuesto por 40.000 muestras correspondientes a recintos no observados durante la fase de optimización. Para la inferencia se ha empleado el punto de control óptimo (*checkpoint*) extraído en la época 540. El rendimiento se cuantifica mediante una doble perspectiva: por un lado, la fidelidad espectral global de la respuesta sintetizada y, por otro, la consistencia de descriptores acústicos físicos derivados de la Curva de Decaimiento de Energía (EDF).

Listing 6.1: Ejecución de la evaluación cuantitativa sobre el conjunto de test/validación.

```
CHECKPOINT_FINAL="/content/drive/MyDrive/TFG_Checkpoints/decor_v5_FINAL_ORO.pth"
DATA_LOCAL="/content/BIRD_Local"
python scripts/eval.py \
    --checkpoint "$CHECKPOINT_FINAL" \
    --data-root "$DATA_LOCAL"
```

Tal como se resume en la Tabla 6.1, el error MSTFT de 8.6108 cuantifica la fidelidad global de la distribución de energía espectrogramática y refleja una correspondencia robusta entre las envolventes espectro-temporales de referencia y las extrapoladas. De forma complementaria, los valores de EDF MAE (5.39 dB) y EDF RMSE (7.26 dB) evidencian un desajuste reducido en la pendiente de la cola reverberante en escala logarítmica, resultado que respalda una coherencia energética de alta precisión en la representación del decaimiento tardío.

Métrica	Valor Medio (μ)
Error Espectral Multiresolución (MSTFT)	8.6108
Error Absoluto Medio de la EDF (EDF MAE) [dB]	5.39
Raíz del Error Cuadrático Medio de la EDF (EDF RMSE) [dB]	7.26
Error Porcentual Absoluto Medio del T_{60} (T_{60} MAPE) [%]	8.1
Error Cuadrático Medio de la Relación Directo-Reverberante (DRR MSE) [dB]	7.24

Tabla 6.1: Métricas de evaluación objetiva sobre el conjunto de test.

En el plano de descriptores macroscópicos, el rendimiento alcanzado mantiene un nivel sobresaliente desde la perspectiva arquitectónica del sistema. El Error Porcentual Absoluto Medio del tiempo de reverberación, expresado como T_{60} MAPE, se asienta en 8.1%, y un margen confinado a un único dígito constituye evidencia empírica de que el decodificador infiere de forma correcta el volumen efectivo y la absorción equivalente de la sala. Finalmente, el DRR MSE de 7.24 dB constata la preservación del balance energético entre el campo acústico directo y el campo difuso, reforzando la validez física de las respuestas impulsionales reconstruidas.

La comparación con modelos de referencia, sintetizada en la Tabla 6.2, permite situar el comportamiento del sistema en un marco competitivo. En dicha tabla, la métrica MSTFT se marca con flecha ascendente ($\uparrow$) para señalar de forma explícita que, en este contraste concreto, el valor del modelo propuesto resulta superior al de Naive y FiNS, es decir, no constituye su punto fuerte cuando se analiza únicamente el error espectral agregado. No obstante, el modelo propuesto exhibe mejoras sustanciales en los descriptores energéticos y macroscópicos de interés acústico, particularmente en EDF MAE, EDF RMSE, T_{60} MAPE y DRR MSE. Este patrón respalda que la arquitectura está orientada a preservar con mayor fidelidad la estructura física del decaimiento reverberante y el balance energético global de la sala, objetivos centrales del presente trabajo.

Modelo	MSTFT ($\downarrow$)	EDF (MAE, dB, $\downarrow$)	EDF (RMSE, dB, $\downarrow$)	T_{60} (MAPE, %, $\downarrow$)	DRR (MSE, dB, $\downarrow$)
DECOR (propuesto)	8.6108	5.39	7.26	8.1	7.24
Naive	2.60	10.4	13.0	29.0	13.9
FiNS	1.05	5.21	7.56	20.1	1.69

Tabla 6.2: Comparativa con modelos de referencia en métricas objetivas. Naive representa la extrapolación directa de la porción temprana sin procesamiento adicional, mientras que FiNS corresponde a la arquitectura propuesta por Steinmetz et al. (2021).

6.3 Caso cualitativo

Con el propósito de interpretar el comportamiento del modelo más allá de las métricas numéricas agregadas, se examina cualitativamente un caso de estudio extraído del subconjunto de evaluación.

Este análisis permite inspeccionar de forma directa la correspondencia entre señal de referencia y señal extrapolada en tres planos complementarios: la forma de onda temporal, la distribución espectro-temporal de energía y la dinámica de decaimiento energético acumulado.




Figura 6.4: Evaluación cualitativa mediante comparación entre la respuesta de referencia (fila superior, *Ground Truth*) y la respuesta sintetizada por DECOR (fila inferior). Las columnas muestran, de izquierda a derecha, la forma de onda temporal de la cola reverberante, las curvas de Decaimiento de Energía multibanda (EDC) y el espectrograma de magnitud. La figura permite contrastar simultáneamente la envolvente temporal, la disipación energética por bandas y la distribución espectro-temporal de la energía entre ambas respuestas.

Tal como se observa en la Figura 6.4, la comparación de la forma de onda temporal puede sintetizarse en los siguientes puntos:

Aciertos del modelo

- **Envolvente de decaimiento.** DECOR reproduce con elevada fidelidad la estructura macro-temporal de la reverberación. La atenuación progresiva de la amplitud a lo largo del tiempo, asociada a la cola reverberante, resulta prácticamente coincidente con la respuesta real.
- **Densidad de la cola reverberante.** A partir del régimen de campo difuso (aproximadamente desde 200 ms), la síntesis mantiene un patrón denso y estocástico coherente con la señal de referencia, convergiendo hacia niveles próximos a cero en un horizonte temporal equivalente.

Puntos de mejora y limitaciones

- **Subestimación de amplitud máxima.** La discrepancia más visible aparece en los picos

iniciales: la señal real alcanza máximos superiores (del orden de 0.3), mientras que la señal estimada presenta picos más contenidos (en torno a 0.2), lo que equivale a una respuesta parcialmente atenuada en escala lineal.

- **Pérdida de estructura fina en reflexiones tempranas.** En el intervalo inicial (aproximadamente 0–100 ms), la respuesta real presenta reflexiones tempranas discretas y bien separadas. La predicción conserva su localización global, pero las representa con mayor aglomeración y menor varianza local, reduciendo nitidez en el detalle microscópico de la onda.

En el dominio espectral, la lectura de la Figura 6.4 puede sintetizarse en los siguientes aspectos:

Aciertos del modelo

- **Envolvente macro y distribución de energía.** La predicción preserva la estructura global del espectrograma, reproduciendo con fidelidad tanto el impacto energético inicial como el decaimiento progresivo en el eje temporal.
- **Decaimiento dependiente de la frecuencia.** Se mantiene un comportamiento físicamente coherente: las componentes de alta frecuencia se extinguen antes, mientras que las bandas bajas y medias conservan energía durante intervalos más prolongados.
- **Alineación temporal del decaimiento.** El instante de agotamiento energético global se sitúa en un entorno temporal concordante con la referencia, lo que respalda una estimación consistente del tiempo reverberante efectivo.

Puntos de mejora y limitaciones

- **Artefactos de filtrado multibanda (Efecto persiana).** Se observan franjas horizontales de atenuación en las frecuencias de cruce (especialmente visibles entre las bandas de 1, 2, 4 y 8 kHz). Este fenómeno es inherente a la arquitectura paramétrica del decodificador: al sintetizar la respuesta mediante un banco discreto de filtros FIR de octava, las regiones de solapamiento espectral entre filtros adyacentes pueden presentar caídas de energía si las envolventes predichas difieren abruptamente, evidenciando las "costuras" del modelo.
- **Supresión severa en altas frecuencias.** Por encima de los 8 kHz, el modelo tiende a atenuar la energía de forma casi absoluta y prematura, formando un muro espectral. Dado el carácter altamente estocástico y difícilmente predecible del aire a esas frecuencias, la red minimiza el error de reconstrucción optando por una supresión temprana.
- **Efecto de suavizado.** La síntesis presenta una textura general más difuminada que la señal medida, cuya microestructura estocástica resulta más rugosa en la cola tardía.

- **Resolución modal en bajas frecuencias.** En la banda baja (aproximadamente 0–128 Hz), las trazas modales verticales se representan con menor nitidez y mayor cuantización espacial.

La comparación de las curvas EDC multibanda, igualmente visible en la columna central de la Figura 6.4, revela el comportamiento termodinámico del sistema:

Aciertos del modelo

- **Conservación de la energía global.** La curva de banda completa (*full-band*, trazo más oscuro) se superpone de forma casi idéntica a la curva de referencia, reflejando que la red inyecta y atenúa la cantidad correcta de energía total en el recinto.
- **Coherencia termodinámica por bandas.** El modelo captura exitosamente la tasa de disipación específica de cada banda de octava, mostrando cómo las altas frecuencias (trazos claros) decaen a un ritmo notablemente superior al de las bajas frecuencias, manteniendo un escalonamiento análogo a la referencia.
- **Estabilidad sin desviaciones sistémicas.** No se observan saltos espurios, oscilaciones anómalas ni desplazamientos persistentes de nivel entre trayectorias, lo que indica una normalización energética robusta.

Puntos de mejora y limitaciones

- **Divergencia en el truncamiento final.** En el entorno previo a la caída abrupta al suelo de ruido, el decaimiento de algunas bandas predichas tiende a suavizarse o retener energía ligeramente más tiempo en comparación con la extinción brusca observada en la referencia empírica.
- **Sensibilidad al ruido de fondo estocástico.** La estimación del instante exacto de corte en la cola final mantiene una dificultad intrínseca elevada en modelos neuronales aplicados a audio, afectando a la precisión del tramo asintótico de las curvas.

En conjunto, pese a las discrepancias localizadas en la microtextura espectral (artefactos de filtrado) y en el truncamiento final, la coincidencia global de patrones respalda que el sistema asimila con elevada precisión la dinámica energética multiexponencial del recinto y confirma su robustez matemática en extrapolación ciega.

6.4 Análisis de Complejidad Computacional

La viabilidad de un modelo de acústica computacional para escenarios interactivos, como la realidad extendida, no queda determinada exclusivamente por su fidelidad termodinámica, sino también

por su eficiencia paramétrica, su huella de memoria y su latencia de inferencia. En aplicaciones de audio inmersivo, estas tres magnitudes condicionan de forma directa la escalabilidad del sistema, la capacidad de despliegue en hardware de propósito general y la posibilidad de integrar la síntesis reverberante en cadenas de procesamiento en tiempo real sin degradar la experiencia perceptiva del usuario.

Modelo	Parámetros (M)	Memoria [MB]	Inferencia [ms]	RTF
DECOR – Propuesto	17.57	67.03	5.36	0.0056
FiNS – Referencia	≈ 340.0	1300.0	N/D	N/D

Tabla 6.3: Comparativa de complejidad computacional, tiempo de inferencia y el Factor de Tiempo Real (RTF) entre el modelo propuesto (DECOR) y el modelo de referencia FiNS.

Desde la perspectiva del tamaño del modelo, la arquitectura propuesta, DECOR, con 17.57 millones de parámetros, se sitúa en una escala marcadamente inferior a la del modelo de referencia FiNS, cuya magnitud paramétrica alcanza aproximadamente 340 millones de parámetros y cuya huella de memoria asciende a 1.3 GB. Esta reducción equivale a un modelo casi 20 veces más ligero, lo cual confirma la eficacia del sesgo inductivo paramétrico incorporado en la formulación. En particular, al modelar explícitamente tasas de decaimiento en lugar de secuencias densas de muestras, el espacio de representación queda restringido a un subespacio físicamente interpretable, reduciéndose de forma sustancial los requisitos de almacenamiento sin comprometer la reconstrucción macroscópica del fenómeno reverberante.

En términos de latencia, el valor de 5.36 ms por inferencia, junto con un Factor de Tiempo Real de 0.0056, demuestra que el sistema sintetiza la reverberación tardía con una velocidad superior en más de 170 veces al tiempo real cuando opera bajo aceleración por hardware. Dicho resultado no constituye únicamente una mejora incremental, sino un indicador objetivo de aptitud operativa para su integración en motores de audio inmersivo, sistemas de realidad extendida y procedimientos de generación masiva de datos acústicos. En consecuencia, la combinación de baja complejidad paramétrica y latencia ultrarreducida certifica que la propuesta no solo es acústicamente consistente, sino también computacionalmente viable para contextos de despliegue exigentes.

Capítulo 7

Conclusiones y Trabajo Futuro

7.1 Conclusiones

El presente Trabajo de Fin de Grado ha resuelto de forma satisfactoria el problema de la extrapolación de la respuesta al impulso tardía a partir de una observación parcial de 50 ms. La evidencia experimental obtenida confirma que la información contenida en el tramo temprano, cuando se procesa mediante una arquitectura físicamente informada, resulta suficiente para reconstruir con consistencia la dinámica energética de la cola reverberante en recintos no observados durante el aprendizaje.

El balance crítico de resultados permite establecer una conclusión de fondo: la arquitectura paramétrica propuesta, DECOR, demuestra que el Procesamiento de Señal Diferenciable (DDSP) introduce un sesgo inductivo termodinámico esencial para el problema abordado. Aunque enfoques puramente generativos del estado del arte pueden optimizar con mayor facilidad distancias espectrales agregadas como MSTFT, su comportamiento evidencia limitaciones estructurales al representar magnitudes físicas del recinto. En contraste, alcanzar un error del 8.1% en la estimación de T_{60} y preservar de manera robusta la Curva de Decaimiento de Energía (EDC) valida la hipótesis central del proyecto: en extrapolación de reverberación tardía, la coherencia acústica constituye un criterio de mayor relevancia que la similitud espectrogramática cruda.

Desde una perspectiva metodológica, también se han consolidado aportaciones de carácter transversal. La estabilización de gradientes mediante técnicas de recorte (*gradient clipping*), junto con una estrategia de aprendizaje por currículo, resultó determinante para alcanzar convergencia en una superficie de pérdida marcadamente no convexa. Esta combinación permitió absorber transitorios de alta inestabilidad durante las fases de acoplamiento físico de la función de coste y condujo a un

régimen final de optimización estable, reproducible y físicamente interpretable.

7.2 Trabajo futuro

Como primera línea de investigación, se propone abordar de forma explícita la síntesis de microestructura estocástica de la cola reverberante, aspecto donde el análisis cualitativo ha identificado limitaciones en factor de cresta y rugosidad fina. Una vía prometedora consiste en acoplar modelos generativos complementarios, tales como Redes Adversarias Generativas o Modelos de Difusión, condicionados por los parámetros físicos estimados por el bloque DDSP. Este esquema híbrido permitiría recuperar detalle microscópico sin comprometer la envolvente macroscópica ni la consistencia energética global.

De forma complementaria, se considera especialmente relevante explorar la extrapolación directa mediante arquitecturas Transformer. Su mecanismo de autoatención podría capturar dependencias temporales de largo alcance entre reflexiones tempranas y cola reverberante, permitiendo modelar con mayor flexibilidad la evolución espectro-temporal sin perder coherencia física cuando se incorporen restricciones acústicas en la función objetivo.

Una segunda línea prioritaria se orienta a la expansión espacial y multicanal del marco actual. En particular, la adaptación a representaciones inmersivas tridimensionales, como Ambisonics o formulaciones basadas en HRTF, abriría la posibilidad de extrapolar no solo la evolución temporal de la energía, sino también la direccionalidad del campo difuso. Esta extensión incrementaría de forma sustancial el alcance aplicado del método en escenarios de Realidad Virtual, auralización interactiva y reproducción espacial avanzada.

Finalmente, se propone profundizar en la optimización de inferencia con el objetivo de viabilizar su despliegue en tiempo real. Entre las estrategias más relevantes se encuentran la destilación del modelo hacia arquitecturas de menor coste computacional y la traslación de componentes críticos a implementaciones de bajo nivel. Este esfuerzo permitiría aproximar el uso de DECOR a plataformas embebidas y sistemas con restricciones estrictas de latencia, favoreciendo su transferencia efectiva a entornos de producción.

Presupuesto y viabilidad económica

7.3 Costes

Para una estimación simple y coherente, se ha considerado un periodo de trabajo de febrero a junio (aprox. 21 semanas) con una dedicación media de 20 horas semanales del estudiante.

Hipótesis utilizadas:

- Horas de estudiante: $21 \times 20 = 420$ h.
- Coste hora estudiante (ingeniero pre-júnior): 18 EUR/h.
- Dedicación de dirección académica (profesor): 16 h totales.
- Coste hora profesor (UPC Terrassa): 70 EUR/h.
- Google Colab Pro: 100 unidades informáticas con coste total de 10 EUR.

Tabla 7.1: Resumen de costes del TFG (estimación simple)

Concepto	Horas / unid.	Coste unitario	Coste total
Estudiante (ingeniero pre-júnior)	420 h	18 EUR/h	7.560 EUR
Profesor (dirección y seguimiento)	16 h	70 EUR/h	1.120 EUR
Google Colab Pro	100 unidades informáticas	0,10 EUR/unidad	10 EUR
Total estimado			8.690 EUR

Esta estimación debe considerarse orientativa y sin impuestos indirectos, y resulta útil para valorar la viabilidad económica del desarrollo en un contexto académico.

Impacto ambiental y social

El desarrollo de modelos de aprendizaje profundo para audio inmersivo no puede evaluarse de forma completa si se omite su dimensión energética. En el presente trabajo, el uso de aceleradores gráficos (GPU) de altas prestaciones ha sido una condición técnica necesaria para entrenar secuencias largas de señal acústica con estabilidad numérica y en tiempos razonables. Sin embargo, esta decisión metodológica conlleva un coste ambiental asociado al consumo eléctrico intensivo durante las fases de optimización.

Desde una perspectiva cuantitativa, la energía consumida durante entrenamiento puede aproximarse por

$$E \approx P_{med} \cdot T, \quad (7.1)$$

donde P_{med} representa la potencia media efectiva del sistema de cómputo y T el tiempo total de uso. A su vez, la huella de carbono operativa puede estimarse como

$$\text{CO}_2\text{eq} \approx E \cdot I_{red}, \quad (7.2)$$

siendo I_{red} la intensidad de carbono de la red eléctrica que alimenta la infraestructura. Este marco evidencia que la eficiencia algorítmica no es únicamente una cuestión de rendimiento computacional, sino también un criterio de responsabilidad ambiental.

Bajo este enfoque, la arquitectura DECOR aporta una ventaja relevante: al introducir sesgo físico mediante DDSF y reducir dimensionalidad efectiva de la síntesis, permite alcanzar objetivos acústicos robustos con complejidad inferior a alternativas puramente generativas de mayor escala. En términos prácticos, una reducción de parámetros, épocas efectivas o tiempo de convergencia se traduce en menor demanda energética por experimento y, por extensión, en menor impacto ambiental acumulado en ciclos iterativos de investigación.

La reflexión social del proyecto se articula en dos planos. Primero, en el plano de acceso tecnológico, el alto coste de entrenamiento sobre GPU de gama alta puede ampliar la brecha entre grupos con distinta capacidad de cómputo. En consecuencia, el diseño de modelos más eficientes constituye también una estrategia de democratización científica. Segundo, en el plano aplicado, la capacidad de extrapolar reverberación realista con menor coste abre oportunidades en educación, accesibilidad y producción audiovisual, al facilitar herramientas acústicas avanzadas en contextos con recursos limitados.

Como criterio de buena práctica, se propone consolidar en trabajos futuros una política de cómputo responsable: monitorización explícita de consumo energético por experimento, reutilización sistemática de *checkpoints*, priorización de búsquedas de hiperparámetros de bajo coste y reporte transparente de métricas de eficiencia junto a las métricas de precisión acústica. Este enfoque permite alinear rigor científico, sostenibilidad ambiental e impacto social positivo en el desarrollo de sistemas de inteligencia artificial para acústica computacional.

Bibliography

- [AB79] Jont B Allen and David A Berkley. “Image method for efficiently simulating small-room acoustics”. In: *The Journal of the Acoustical Society of America* 65.4 (1979), pp. 943–950.
- [Bor84] Jeffrey Borish. “Extension of the image model to arbitrary polyhedra”. In: *The Journal of the Acoustical Society of America* 75.6 (1984), pp. 1827–1836.
- [DP10] G. Defrance and J.-D. Polack. “Estimating the mixing time of concert halls using the eXtensible Fourier Transform”. In: *Applied Acoustics* 71.9 (2010), pp. 777–792. ISSN: 0003-682X. DOI: <https://doi.org/10.1016/j.apacoust.2010.05.011>. URL: <https://www.sciencedirect.com/science/article/pii/S0003682X10001180>.
- [Dzi+21] Damian Dziwis et al. “Machine Learning-Based Room Classification for Selecting Binaural Room Impulse Responses in Augmented Reality Applications”. In: Sept. 2021, pp. 1–8. DOI: [10.1109/I3DA48870.2021.9610915](https://doi.org/10.1109/I3DA48870.2021.9610915).
- [GBC16] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT press, 2016.
- [Gro+20] François Grondin et al. “BIRD: Big Impulse Response Dataset”. In: *ArXiv abs/2010.09930* (2020). URL: <https://api.semanticscholar.org/CorpusID:224803038>.
- [Kar+24] Xenofon Karakostas et al. “Room impulse response reconstruction with physics-informed deep learning”. In: *The Journal of the Acoustical Society of America* 155.2 (Feb. 2024), pp. 1048–1059. ISSN: 0001-4966. DOI: [10.1121/10.0024750](https://doi.org/10.1121/10.0024750). eprint: https://pubs.aip.org/asa/jasa/article-pdf/155/2/1048/19508065/1048_1_10.0024750.pdf. URL: <https://doi.org/10.1121/10.0024750>.
- [KSS68] Asbjørn Krokstad, Svein Strøm, and Svein Sørsdal. “Calculating the acoustical room response by the use of a ray tracing technique”. In: *Journal of sound and vibration* 8.1 (1968), pp. 118–125.
- [Kut16] Heinrich Kuttruff. *Room Acoustics*. 6th. CRC Press, 2016.
- [LGS25] Jackie Lin, Georg Götz, and Sebastian Schlecht. “Deep room impulse response completion”. In: *EURASIP Journal on Audio, Speech, and Music Processing* 2025 (May 2025), p. 20. DOI: [10.1186/s13636-024-00383-1](https://doi.org/10.1186/s13636-024-00383-1).

- [RC07] Jens Rindel and Claus Christensen. “ODEON, A DESIGN TOOL FOR NOISE CONTROL IN INDOOR ENVIRONMENTS”. In: July 2007.
- [Sch65] Manfred R Schroeder. “New method of measuring reverberation time”. In: *The Journal of the Acoustical Society of America* 37.3 (1965), pp. 409–412.
- [SIC21] Christian J. Steinmetz, Vamsi Krishna Ithapu, and Paul Calamia. “Filtered noise shaping for time domain room impulse response estimation from reverberant speech”. In: *Proceedings of the IEEE Workshop on Applications of Signal Processing to Audio and Acoustics (WASPAA)*. Online conference. 2021.
- [ZK25] Yongyi Zang and Qiuqiang Kong. “GSound-SIR: A Spatial Impulse Response Ray-Tracing and High-order Ambisonic Auralization Python Toolkit”. In: *arXiv preprint arXiv:2503.17866* (2025). URL: <https://arxiv.org/abs/2503.17866>.