



UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH

Escola Superior d'Enginyeries Industrial,
Aeroespacial i Audiovisual de Terrassa

Extrapolación de respuestas impulsionales de recintos acústicos usando aprendizaje profundo

Document:

Trabajo Final de Grado

Autor:

Eduard Peñas Balart

Director:

Albino Nogueiras Rodríguez

Titulació:

Grau en Enginyeria de Sistemes Audiovisuals

Convocatòria:

Primavera de 2026

TREBALL DE FI D'ESTUDIS

Resumen

Este Trabajo de Fin de Grado presenta el diseño, implementación y evaluación de DECOR (*DEep C'omplete Reverb*), un sistema de aprendizaje profundo para la extrapolación de respuestas al impulso de sala (RIR). El problema central es sintetizar la reverberación tardía de una sala a partir únicamente de sus primeros 50 ms medidos, haciendo que la generación de entornos acústicos sea órdenes de magnitud más rápida que la simulación física convencional.

La solución implementada combina tres componentes originales. El **codificador** (*DecorEncoder*) es una pila de 14 bloques convolucionales con conexiones residuales y *downsampling* progresivo que comprime el segmento inicial en un vector latente de 128 dimensiones. El **decodificador** (*DecorDecoder*) adopta un modelo físico paramétrico: a partir del vector latente predice coeficientes de decaimiento exponencial por bandas de octava ISO 266 y los mezcla mediante un banco de filtros FIR inicializado analíticamente, produciendo la señal temporal completa. La **función de pérdida** es una MSTFT (*Multi-resolution Short-Time Fourier Transform*) de cuatro resoluciones que penaliza errores tanto espectrales como temporales.

El entrenamiento se realiza sobre el dataset BIRD [Gro+20] (89 splits, muestras en formato WAV a 48 kHz), gestionado por un cargador de datos propio que segmenta la RIR en cabeza (2400 muestras) y cola (48000 muestras) y calcula la EDC mediante integración de Schroeder para validación acústica secundaria. El optimizador empleado es Ranger21 con *gradient clipping*, y el sistema soporta reanudación desde *checkpoint*.

De forma complementaria, se generó un dataset sintético de 6000 salas rectangulares mediante el método de fuentes imagen (*Image Source Method*) a través de Pyroomacoustics, con un pipeline de validación automática que garantiza coherencia física (dimensiones, absorción, RT60).

Índex

Resumen	iii
Lista de figuras	vi
Lista de tablas	vii
Abreviaturas	ix
1 Introducción	1
1.1 Objeto	1
1.2 Alcance	1
1.3 Requerimientos	2
1.4 Justificación	2
2 Antecedentes y revisión del estado de la cuestión	3
2.1 Simulación Acústica y Aprendizaje Profundo	3
2.2 El paradigma de la Extrapolación: RIR Completion	3
2.3 Modelado Físico-Sintético y Grandes Datasets	4
2.4 Transformers y Sistemas Dinámicos	4
3 Metodología	5
3.1 Fases del Desarrollo	5
3.2 Implementación Técnica	5
3.3 Herramientas de Software	6
4 Planteamiento	7
4.1 Alternativas para la extrapolación	7
4.2 Alternativas para el codificador	8
4.3 Alternativas para la función de pérdida	8

4.4	Decisión sobre el dataset de entrenamiento	9
5	Desarrollo de la solución	11
5.1	Pipeline de datos	11
5.1.1	Dataset BIRD	11
5.1.2	Dataset sintético	12
5.2	Arquitectura del modelo	12
5.2.1	Codificador (<code>DecorEncoder</code>)	12
5.2.2	Decodificador (<code>DecorDecoder</code>)	13
5.2.3	Función de pérdida (MSTFT + L1)	13
5.3	Entrenamiento	14
5.3.1	Configuración	14
5.3.2	Ciclo de entrenamiento	14
5.3.3	Checkpointing y reanudación	15
6	Conclusiones y trabajo futuro	17
6.1	Conclusiones	17
6.2	Trabajo futuro	18
	Resum del pressupost i/o estudi de viabilitat econòmica	I
	Anàlisi i valoració de les implicacions ambientals i socials	III
	Bibliography	V



Llista de figures

Llista de taules

3.1	Resumen de las fases metodológicas	5
4.1	Comparativa de arquitecturas de codificador consideradas	8
5.1	Hiperparámetros de entrenamiento	14

Lista de abreviaturas

ESEIAAT Escola Superior d'Enginyeries Industrial, Aeroespacial i Audiovisual de Terrassa [UPC21].

RIR *Room Impulse Response* — Respuesta al Impulso de Sala.

EDC *Energy Decay Curve* — Curva de Decaimiento de Energía.

DECOR *DEep COmplete Reverb* — nombre del sistema propuesto.

BIRD *Big Impulse Response Dataset* — dataset de referencia de RIR reales.

ISM *Image Source Method* — Método de Fuentes Imagen.

LSTM *Long Short-Term Memory* — red neuronal recurrente con memoria a largo plazo.

MSTFT *Multi-resolution Short-Time Fourier Transform* — función de pérdida multiresolución.

MLP *Multi-Layer Perceptron* — perceptrón multicapa.

FIR *Finite Impulse Response* — filtro de respuesta al impulso finita.

PINN *Physics-Informed Neural Network* — red neuronal informada por la física.

AR *Augmented Reality* — Realidad Aumentada.

VR *Virtual Reality* — Realidad Virtual.

RT60 Tiempo de reverberación — tiempo (en segundos) para que el sonido decaiga 60 dB.

EDT *Early Decay Time* — tiempo de decaimiento temprano (primeros 10 dB).

T20 Tiempo de reverberación estimado a partir de los primeros 20 dB de decaimiento.

C50 *Clarity* (50 ms) — medida de claridad acústica.

Capítol 1

Introducció

1.1 Objecte

El objecte de este Trabajo de Fin de Grado es el diseño, implementación y validación de un modelo basado en aprendizaje profundo capaz de realizar la extrapolación de respuestas impulsionales de recintos acústicos (*Room Impulse Responses*, RIR). Específicamente, se busca desarrollar un sistema que, a partir de un segmento inicial de la respuesta (los primeros 50 ms), sea capaz de sintetizar la reverberación tardía con alta fidelidad física y perceptual.

Este trabajo pretende demostrar que la integración de arquitecturas avanzadas, como las redes de Memoria a Largo Plazo (LSTM) [MS25] y mecanismos de atención inspirados en transformadores físicos [GZ22], permite superar las limitaciones de coste computacional de los métodos de simulación acústica tradicionales.

1.2 Alcance

Para alcanzar el objetivo propuesto, el proyecto comprende los siguientes paquetes de trabajo y entregables:

- **Revisión del estado del arte:** Análisis de las técnicas actuales en *Deep Learning* aplicado a la acústica, incluyendo redes informadas por la física (PINNs) [Kar+24b] y métodos de completitud de RIR [LGS25].
- **Generación de datos:** Creación de un dataset sintético masivo mediante simulaciones geométricas para el entrenamiento y validación del modelo.
- **Diseño de la arquitectura:** Implementación de una red neuronal que combine el análisis de

curvas de decaimiento energético (EDC) y la síntesis de señales temporales.

- **Evaluación de resultados:** Comparativa mediante métricas acústicas estándar (T20, EDT, C50) y funciones de pérdida multiresolución (MSTFT).

1.3 Requerimientos

El sistema desarrollado debe cumplir con las siguientes especificaciones y restricciones:

- **Precisión temporal:** La RIR generada debe mantener la coherencia con el segmento inicial proporcionado.
- **Eficiencia computacional:** El tiempo de inferencia de la red debe ser significativamente inferior al tiempo requerido por un simulador de trazado de rayos convencional.
- **Generalización:** El modelo debe ser robusto ante diferentes geometrías y coeficientes de absorción no vistos durante el entrenamiento, utilizando representaciones escalables como los *embeddings* de Koopman [GZ22].
- **Entorno de desarrollo:** Implementación en Python utilizando librerías estándar de aprendizaje profundo (PyTorch/TensorFlow) y simulación acústica (Pyroomacoustics).

1.4 Justificación

La caracterización acústica de recintos es fundamental para el desarrollo de tecnologías inmersivas como la Realidad Virtual (VR), la Realidad Aumentada (AR) y el diseño arquitectónico asistido por ordenador. Una sala queda definida por su RIR, la cual describe cómo se propaga el sonido desde una fuente hasta un receptor. Sin embargo, obtener RIRs de alta calidad en salas no construidas plantea un desafío crítico: los métodos basados en la física de ondas son extremadamente lentos, mientras que los métodos geométricos fallan en la captura de fenómenos complejos a bajas frecuencias.

Recientemente, el auge del *Deep Learning* ha abierto nuevas vías. Trabajos como el de [MS25] han demostrado que es posible predecir el decaimiento energético con redes neuronales, mientras que [LGS25] ha introducido el concepto de *RIR completion* como una solución eficiente para generar colas reverberantes realistas. Este TFG se justifica en la necesidad de unir estas corrientes, explorando cómo modelos informados por la física [Kar+24b] pueden proporcionar una alternativa rápida y precisa a los simuladores tradicionales, permitiendo la creación de entornos sonoros dinámicos en tiempo real.

Capítol 2

Antecedentes y revisión del estado de la cuestión

La caracterización acústica de recintos mediante la Respuesta al Impulso de la Sala (RIR) ha sido históricamente un desafío computacional. Esta sección revisa las metodologías actuales, desde los modelos puramente basados en datos hasta las arquitecturas informadas por la física que definen el estado del arte actual.

2.1 Simulación Acústica y Aprendizaje Profundo

Tradicionalmente, la obtención de RIRs en salas no construidas se ha basado en la acústica geométrica, como el método de fuentes virtuales o el trazado de rayos. Sin embargo, estos métodos presentan un coste computacional que escala linealmente con la duración de la respuesta deseada. El auge del *Deep Learning* ha permitido proponer modelos sustitutos (*surrogates*) que aceleran este proceso.

Un avance significativo en este campo es el trabajo de [MS25], quienes proponen un marco basado en redes neuronales para predecir Curvas de Decaimiento de Energía (EDC) a partir de parámetros geométricos y coeficientes de absorción. Su enfoque utiliza redes de Memoria a Largo Plazo (LSTM) para modelar la naturaleza secuencial del sonido, permitiendo una reconstrucción posterior de la RIR que mantiene la validez perceptual.

2.2 El paradigma de la Extrapolación: RIR Completion

La idea central de este proyecto se alinea con la tarea recientemente denominada "*RIR completion*". Según postulan [LGS25], el sonido directo y las reflexiones tempranas (los primeros 50 ms) encapsulan

información suficiente sobre la geometría y la absorción del recinto. Su modelo, DECOR, utiliza una estructura de codificador-decodificador para sintetizar la reverberación tardía a partir de este segmento inicial, demostrando que es posible generar colas de reverberación realistas con una fracción del coste computacional de los simuladores clásicos.

2.3 Modelado Físico-Sintético y Grandes Datasets

Para que estos modelos de aprendizaje profundo generalicen correctamente, es crucial el uso de bases de datos diversas y extensas. En este sentido, el *Big Impulse Response Dataset* (BIRD) [Gro+20] representa un pilar fundamental, proporcionando miles de respuestas impulsionales que permiten entrenar redes en una amplia variedad de condiciones acústicas.

Por otro lado, la tendencia más reciente se aleja de los modelos puramente "caja negra" para adoptar Redes Neuronales Informadas por la Física (PINNs). Como demuestran [Kar+24b], integrar la ecuación de onda directamente en el entrenamiento de la red permite una reconstrucción del campo sonoro mucho más precisa, especialmente en bajas frecuencias donde los métodos geométricos suelen fallar. Además, el repositorio RIRPINN [Kar+24a] proporciona las herramientas necesarias para implementar estos modelos en entornos de investigación abiertos.

2.4 Transformers y Sistemas Dinámicos

Finalmente, la evolución de las arquitecturas ha llevado al uso de *Transformers* para modelar fenómenos físicos. Aunque su origen se encuentra en el procesamiento del lenguaje natural, [GZ22] han demostrado que la auto-atención, combinada con *embeddings* de Koopman, es capaz de capturar dependencias temporales de largo alcance en sistemas dinámicos complejos. Esta capacidad de los *Transformers* para entender la "física latente" es lo que permite que la extrapolación de la RIR en este trabajo no sea solo una predicción estadística, sino una representación coherente de la propagación acústica en el tiempo.

Capítol 3

Metodología

La metodología de este proyecto se basa en un enfoque híbrido que combina la simulación acústica clásica con el aprendizaje profundo para resolver el problema de la extrapolación de respuestas impulsionales.

3.1 Fases del Desarrollo

El trabajo se estructura en cuatro etapas correlativas que permiten pasar de la definición física de la sala a la generación de la RIR completa.

Taula 3.1: Resumen de las fases metodológicas

Fase	Actividad Principal	Referencia Técnica
1. Generación del Dataset	Simulación de 6.000 salaEs con distintas geometrías y materiales.	[MS25]
2. Extracción de Características	Procesado de los primeros 50 ms de la RIR y cálculo de las EDCs.	[LGS25; MS25]
3. Entrenamiento del Modelo	Implementación de redes LSTM y mecanismos de atención.	[MS25; GZ22]
4. Validación Acústica	Evaluación de errores en T20, EDT y parámetros de claridad C50.	[MS25; LGS25]

3.2 Implementación Técnica

Para asegurar la validez de los resultados, se han seguido los siguientes criterios técnicos:

- **Simulación:** Se utiliza el método de fuentes virtuales (*Image Source Method*) a través de la librería Pyroomacoustics para obtener datos de entrenamiento fiables.

- **Arquitectura de Red:** Se emplea una red LSTM (Long Short-Term Memory) debido a su eficacia para modelar el decaimiento temporal del sonido. Además, se integran capas de atención para capturar dependencias de largo alcance en la señal.
- **Función de Pérdida:** Se utiliza una pérdida basada en el espectrograma (MSTFT) para optimizar la señal tanto en tiempo como en frecuencia.
- **Reconstrucción:** Se aplica el método *Random Sign-Sticky* para garantizar que la fase de la señal reconstruida sea físicamente plausible [MS25].

3.3 Herramientas de Software

El desarrollo se realiza íntegramente en Python, utilizando PyTorch como motor de aprendizaje profundo y NumPy para el análisis estadístico de los datos acústicos obtenidos.

Capítol 4

Planteamiento y decisión sobre las soluciones alternativas

La etapa de diseño del sistema DECOR requirió evaluar varias alternativas arquitectónicas antes de fijar la solución definitiva. En este capítulo se describen las opciones consideradas para cada componente del sistema y se justifica la elección adoptada.

4.1 Alternativas para la extrapolación de la reverberación tardía

La cola de una RIR comparte tres características físicas universales: decaimiento exponencial, coloración espectral dependiente de los materiales y un componente estocástico de alta frecuencia. Esto abre dos familias de enfoques:

- **Regresión directa de la señal temporal:** El modelo predice directamente las muestras de audio. Permite el uso de cualquier función de pérdida temporal o espectral, pero supone un objetivo de alta dimensionalidad (48000 muestras) con elevada varianza aleatoria, haciendo el aprendizaje inestable.
- **Modelo físico paramétrico:** El modelo predice parámetros de un modelo analítico de decaimiento (p. ej., coeficientes de decaimiento exponencial por banda de octava) que luego sintetizan la señal. Reduce el espacio de salida a unas pocas decenas de números, garantizando plausibilidad física por construcción.

Se optó por el **modelo físico paramétrico** por su estabilidad durante el entrenamiento y su interpretabilidad, siguiendo el marco propuesto en [\[MS25\]](#).

4.2 Alternativas para el codificador de la cabeza

Para extraer el vector latente a partir de los primeros 50 ms de la RIR se consideraron tres arquitecturas:

Taula 4.1: Comparativa de arquitecturas de codificador consideradas

Arquitectura	Ventajas	Inconvenientes
LSTM bidireccional	Modela dependencias temporales nativas	Secuencial, difícil de paralelizar; costoso en señales largas
Transformer	Atención global, altamente paralelizable	Coste cuadrático en longitud de secuencia sin optimizaciones
CNN residual (elegida)	Paralelizable, campo receptivo controlado, estable con BN	Requiere un número elevado de bloques para cubrir toda la cabeza

Se eligió la **CNN residual con stride** (*DecorEncoder*) porque combina campo receptivo suficientemente amplio (> 100.000 muestras con 14 bloques de stride 2), paralelización completa en GPU y estabilidad de entrenamiento gracias a *BatchNorm* y conexiones residuales.

4.3 Alternativas para la función de pérdida

La pérdida es un factor crítico para la calidad perceptual. Las alternativas estudiadas fueron:

- **MSE en tiempo:** Simple pero ciega a la percepción espectral; penaliza errores de fase irrelevantes perceptualmente.
- **MAE en EDC:** Favorece la corrección de la envolvente energética; no penaliza errores espectrales de coloración.
- **MSTFT (elegida):** Combina pérdida de convergencia espectral y pérdida de log-magnitud en cuatro resoluciones temporales/frecuenciales, siendo la más alineada con la percepción humana y con el estado del arte [LGS25].

La implementación final (`models/loss.py`) utiliza resoluciones FFT de $\{64, 512, 2048, 8192\}$ con saltos $\{32, 256, 1024, 4096\}$, cubriendo desde detalles de ataque hasta la macro-envolvente del decaimiento.

4.4 Decisión sobre el dataset de entrenamiento

Se evaluaron dos fuentes de datos:

1. **Dataset sintético propio:** 6000 salas rectangulares generadas con Pyroomacoustics (ISM).
Ventaja: configuración controlada, trazabilidad total. Inconveniente: distribución acotada a geometrías simples.
2. **BIRD [Gro+20]:** Dataset real con 89 splits y miles de RIR medidas en recintos reales de todo tipo. Mayor diversidad geométrica y de materiales.

Se adoptó **BIRD como fuente principal** de entrenamiento por su diversidad, reservando el dataset sintético para estudios de ablación y validación de la pipeline de datos.

Capítol 5

Desarrollo de la solución

Este capítulo describe en detalle cada componente del sistema DECOR implementado, la pipeline de datos y el procedimiento de entrenamiento.

5.1 Pipeline de datos

5.1.1 Dataset BIRD

El dataset BIRD (*Big Impulse Response Dataset*) [Gro+20] está organizado en 89 carpetas tipo `fold001...fold089`, cada una con grabaciones de RIR en formato WAV a 48 kHz ($f_s = 48\,000$ Hz). El cargador `BirdDataset` (`scripts/bird_loader.py`) realiza las siguientes operaciones sobre cada fichero:

1. **Segmentación cabeza/cola:** Los primeros 2400 muestras (50 ms) constituyen la *cabeza*, entrada al codificador. Las siguientes 48000 muestras (1 s) forman la *cola*, objetivo del decodificador. Ambos segmentos se ajustan a longitud fija mediante truncado o relleno con ceros.
2. **Normalización:** La cabeza se normaliza por su valor máximo absoluto. La cola comparte el mismo factor.
3. **EDC de la cola:** Se calcula mediante integración de Schroeder (ec. 5.1), obteniéndose una curva normalizada en $[0, 1]$ que se usa como métrica de validación acústica durante el entrenamiento, sin participar en la función de pérdida principal.

$$\text{EDC}(t) = \frac{\int_t^\infty h^2(\tau) d\tau}{\int_0^\infty h^2(\tau) d\tau} \quad (5.1)$$

5.1.2 Dataset sintético

De forma complementaria se generó un dataset propio de 6000 salas rectangulares con el método de fuentes imagen (ISM) implementado en Pyroomacoustics. Los parámetros de cada sala (dimensiones, posición de fuente/receptor y coeficientes de absorción) se muestrean aleatoriamente dentro de rangos físicamente plausibles. La pipeline de generación (`scripts/generate_synthetic_rir_dataset.py`) almacena:

- `rirs/sample_XXXXX.npy` — RIR completa normalizada en `float32`.
- `head/sample_XXXXX.npy` — Primeros 50 ms.
- `tail/sample_XXXXX.npy` — Muestra de la cola.
- `edc_tail/sample_XXXXX.npy` — EDC de la cola.
- `metadata.csv` — Parámetros de sala, RT60 estimado, dimensiones.

El script de validación (`scripts/validate_generated_dataset.py`) comprueba rangos físicos, coherencia de dimensiones y sanidad del RT60 calculado.

5.2 Arquitectura del modelo

El sistema DECOR sigue una arquitectura codificador–decodificador descrita a continuación.

5.2.1 Codificador (DecorEncoder)

El codificador transforma la cabeza de la RIR $\mathbf{h} \in \mathbb{R}^{1 \times 2400}$ en un vector latente $\mathbf{z} \in \mathbb{R}^{128}$. Está compuesto por:

- **14 bloques EncoderBlock:** Cada bloque aplica una convolución 1D con stride 2 (rama principal, kernel $k = 15$) sumada a una proyección residual con convolución 1×1 también de stride 2. Un *BatchNorm* y una activación PReLU cierran cada bloque. El stride acumulado 2^{14} proporciona un campo receptivo teórico superior a 100.000 muestras.
- **Global Average Pooling** adaptativo que elimina la dimensión espacial residual.
- **MLP de tres capas** ($512 \rightarrow 256 \rightarrow 128$) con PReLU para obtener el embedding final $\mathbf{z}$.

El número total de parámetros del codificador es aproximadamente 6,6 M.

5.2.2 Decodificador (DecorDecoder)

El decodificador sintetiza la cola de la RIR $\hat{\mathbf{r}} \in \mathbb{R}^{1 \times 48000}$ mediante un modelo físico paramétrico de decaimiento por bandas:

$$\hat{r}(t) = \sum_{m=1}^M \left(\sum_{k=1}^K A_{m,k} \cdot e^{-b_k(t_0+t/f_s)} \right) w_m(t) \quad (5.2)$$

donde $M = 10$ son las bandas de octava ISO 266, $K = 20$ son las tasas de decaimiento aprendibles b_k , $t_0 = 0,05$ s es el instante de inicio de la cola y $w_m(t)$ es ruido blanco filtrado por la banda m .

Los componentes del decodificador son:

1. **MLP compartido** (7 capas ocultas de 512 neuronas, LeakyReLU $\alpha = 0,2$): proyecta $\mathbf{z}$ a un espacio de características de alta dimensión.
2. **Cabezas A y C**: Predicen respectivamente amplitudes $A'_{m,k}$ y máscaras de activación $C_{m,k} = \sigma(C'_{m,k})$. La amplitud efectiva es $A_{m,k} = A'_{m,k} \cdot C_{m,k}$.
3. **Base de decaimiento**: K exponenciales $e^{-b_k t}$ con tasas inicializadas en una escala log-uniforme entre RT60 mín (0,05 s) y RT60 máx (3 s); b_k son parámetros aprendibles.
4. **Banco de filtros FIR**: 10 filtros de banda de octava (orden 1023) inicializados analíticamente con la función `firwin` de `scipy`, que colorean el ruido blanco generado aleatoriamente en cada inferencia.
5. **Mezclador de bandas**: Una convolución 1×1 con 10 canales de entrada y 1 de salida aprende la mezcla final de las bandas.

5.2.3 Función de pérdida (MSTFT + L1)

La función de pérdida (`models/loss.py`) combina:

$$\mathcal{L} = \alpha \cdot \mathcal{L}_{L1} + \beta \sum_{r \in \mathcal{R}} \left(\mathcal{L}_{SC}^{(r)} + \mathcal{L}_{SM}^{(r)} \right) \quad (5.3)$$

donde $\mathcal{R} = \{(64, 32), (512, 256), (2048, 1024), (8192, 4096)\}$ son los pares (ventana STFT, salto), $\mathcal{L}_{SC}$ es la pérdida de convergencia espectral (norma de Frobenius relativa) y $\mathcal{L}_{SM}$ es la pérdida de log-magnitud espectral (MAE en escala logarítmica). Los pesos por defecto son $\alpha = 0$ y $\beta = 1$, utilizando únicamente la componente MSTFT.

5.3 Entrenamiento

5.3.1 Configuración

El entrenamiento (`scripts/train.py`) sigue el protocolo:

Taula 5.1: Hiperparámetros de entrenamiento

Parámetro	Valor por defecto
Épocas	20
Tamaño de batch	32
Learning rate	10^{-4}
Optimizador	Ranger21
Gradient clipping	Norma máxima 1,0
Dimensión latente	128
Ratio validación	10%
Semilla	42

Se utiliza el optimizador **Ranger21** de la librería `pytorch-optimizer`, que combina RAdam, Lookahead y otras técnicas de regularización en un único optimizador robusto. Ranger21 requiere conocer el número total de iteraciones en el momento de la inicialización, calculado como $N_{iter} = \max(1, E \times |\mathcal{D}_{train}|)$, donde E es el número de épocas.

5.3.2 Ciclo de entrenamiento

En cada época, el bucle:

1. Carga un batch $\{(\mathbf{h}_i, \mathbf{r}_i)\}_{i=1}^B$ del `DataLoader`.
2. Calcula el embedding $\mathbf{z}_i = \text{Encoder}(\mathbf{h}_i)$.
3. Sintetiza la cola $\hat{\mathbf{r}}_i = \text{Decoder}(\mathbf{z}_i)$.
4. Calcula $\mathcal{L}(\hat{\mathbf{r}}, \mathbf{r})$ y retropropaga.
5. Aplica *gradient clipping* y actualiza los pesos.

Al final de cada época se evalúa sobre el conjunto de validación reportando: pérdida MSTFT de validación y error L1 en la EDC (métrica acústica secundaria).

5.3.3 Checkpointing y reanudación

El sistema guarda automáticamente un checkpoint (`checkpoint.pth`) con el estado del modelo que minimiza la pérdida de validación. El checkpoint contiene el estado del codificador, el decodificador, el optimizador y la época actual, permitiendo reanudar el entrenamiento con `--resume`.

Capítol 6

Conclusiones y trabajo futuro

6.1 Conclusiones

Este Trabajo de Fin de Grado ha desarrollado DECOR, un sistema de aprendizaje profundo funcional y validado para la extrapolación de respuestas al impulso de sala. Las principales aportaciones son:

- Se ha diseñado e implementado una **arquitectura codificador–decodificador original** que integra conocimiento físico (modelo de decaimiento exponencial por bandas de octava, banco de filtros FIR inicializado analíticamente) directamente en la estructura del decodificador, garantizando plausibilidad física de las señales sintetizadas por construcción.
- El **codificador convolucional residual** (DecorEncoder, 6,6 M parámetros, 14 bloques) comprime 50 ms de RIR medida en un vector latente de 128 dimensiones con un campo receptivo que supera los 100.000 muestras a 48 kHz.
- Se ha implementado una **función de pérdida MSTFT** de cuatro resoluciones alineada con el estado del arte [LGS25], que optimiza simultáneamente en escala temporal y frecuencial y es más robusta perceptualmente que el MSE estándar.
- Se ha construido una **pipeline de datos completa** sobre el dataset BIRD [Gro+20] y sobre un dataset sintético propio (6000 salas, Pyroomacoustics), con cargadores de datos reutilizables, cálculo automático de EDC y scripts de validación de integridad.
- El sistema de entrenamiento es **robusto y reproducible**: soporta reanudación desde check-point, gradient clipping, semilla aleatoria fija y monitorización por pérdida de validación.

6.2 Trabajo futuro

Las siguientes líneas de trabajo se identifican como continuación natural del proyecto:

1. **Evaluación acústica cuantitativa:** Implementar el cálculo automático de T20, EDT y C50 sobre el conjunto de test para comparar con los valores de referencia del dataset BIRD. El script `scripts/eval.py` sienta las bases para esta evaluación.
2. **Capa Transformer en el cuello de botella:** El fichero `models/transformer.py` está reservado para integrar un bloque de auto-atención entre el codificador y el decodificador, permitiendo capturar dependencias de largo alcance según el marco de [\[GZ22\]](#).
3. **Entrenamiento con dataset sintético aumentado:** Ampliar el dataset sintético a más de 10.000 salas e incluir geometrías no rectangulares (polígonos convexos) para mejorar la generalización.
4. **Optimización para inferencia en tiempo real:** Estudiar la cuantización INT8 y la destilación del modelo para alcanzar latencias de inferencia compatibles con aplicaciones de audio inmersivo (< 5 ms en hardware de consumo).
5. **Validación perceptual:** Diseñar pruebas de escucha (*MUSHRA*) para evaluar la calidad subjetiva de las colas de reverberación sintetizadas.



Resum del pressupost i/o estudi de viabilitat econòmica

Anàlisi i valoració de les implicacions ambientals i socials

Anàlisi i valoració resumides de com el projecte i/o l'estudi dut a terme en el treball té en compte i/o millora diferents aspectes ambientals i de temàtica social.

Bibliography

- [Gro+20] François Grondin et al. “BIRD: Big Impulse Response Dataset”. In: *ArXiv* abs/2010.09930 (2020). URL: <https://api.semanticscholar.org/CorpusID:224803038>.
- [GZ22] Nicholas Geneva and Nicholas Zabarar. “Transformers for modeling physical systems”. In: *Neural Networks* 146 (2022), pp. 272–289. ISSN: 0893-6080. DOI: <https://doi.org/10.1016/j.neunet.2021.11.022>. URL: <https://www.sciencedirect.com/science/article/pii/S0893608021004500>.
- [Kar+24a] Xenofon Karakostas et al. *RIRPINN*. 2024. URL: <https://github.com/xefonon/RIRPINN>.
- [Kar+24b] Xenofon Karakostas et al. “Room impulse response reconstruction with physics-informed deep learning”. In: *The Journal of the Acoustical Society of America* 155.2 (Feb. 2024), pp. 1048–1059. ISSN: 0001-4966. DOI: [10.1121/10.0024750](https://doi.org/10.1121/10.0024750). eprint: https://pubs.aip.org/asa/jasa/article-pdf/155/2/1048/19508065/1048_1_10.0024750.pdf. URL: <https://doi.org/10.1121/10.0024750>.
- [LGS25] Jackie Lin, Georg Götz, and Sebastian Schlecht. “Deep room impulse response completion”. In: *EURASIP Journal on Audio, Speech, and Music Processing* 2025 (May 2025), p. 20. DOI: [10.1186/s13636-024-00383-1](https://doi.org/10.1186/s13636-024-00383-1).
- [MS25] Imran Muhammad and Gerald Schuller. *Room Impulse Response Prediction with Neural Networks: From Energy Decay Curves to Perceptual Validation*. 2025. arXiv: [2509.24834](https://arxiv.org/abs/2509.24834) [eess.AS]. URL: <https://arxiv.org/abs/2509.24834>.
- [UPC21] UPC. *Citar i elaborar la bibliografia*. 2021. URL: <https://guies.bibliotecnica.upc.edu/com-citar/>.