



UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH

Escola Superior d'Enginyeries Industrial,
Aeroespacial i Audiovisual de Terrassa

Extrapolación de respuestas impulsionales de recintos acústicos usando aprendizaje profundo

Documento:

Trabajo Final de Grado

Autor:

Eduard Peñas Balart

Director:

Albino Nogueiras Rodríguez

Titulación:

Grado en Ingeniería de Sistemas Audiovisuales

Convocatoria:

Primavera de 2026

TREBALL DE FI D'ESTUDIS

Resum

La síntesi de respostes impulsional de sala (RIR) completes mitjancant simulació acústica convencional presenta un cost computacional elevat. Aquest treball parteix de la hipòtesi que la porció inicial d'una RIR (els primers 50 ms), que conté el so directe i les reflexions primerenques, incorpora informació suficient sobre la geometria i les propietats acústiques del recinte per reconstruir-ne la reverberació tardana.

S'ha desenvolupat DECOR (*Deep Exponential Completion Of Room impulse responses*), una arquitectura codificador-decodificador orientada a la completació de RIR. El codificador comprimeix la capçalera de la RIR (2400 mostres a 48 kHz) mitjancant nou blocs convolucional amb connexions *skip* i reducció progressiva de la resolució temporal, obtenint un vector latent de 128 dimensions. El decodificador, guiat per un model físic de soroll blanc amb decaïment exponencial, estima envoltants multiexponencials que modulen seqüències de soroll filtrat a través d'un banc de deu filtres FIR en bandes d'octava ISO 266. Aquesta formulació introdueix biaix acústic amb l'objectiu de reduir la mida del model preservant capacitat representacional.

L'eficàcia de la proposta s'ha validat mitjancant comparació amb una arquitectura d'estat de l'art de mida considerablement superior. Els resultats indiquen que DECOR assoleix un rendiment competitiu amb una complexitat substancialment menor, i confirmen la viabilitat de la completació de RIR com a estratègia pràctica per a l'extrapolació de reverberació tardana.

Resumen

La síntesis de respuestas impulsionales de sala (RIR) completas mediante simulación acústica convencional presenta un coste computacional elevado. Este trabajo parte de la hipótesis de que la porción inicial de una RIR (los primeros 50 ms), que contiene el sonido directo y las reflexiones tempranas, incorpora información suficiente sobre la geometría y las propiedades acústicas del recinto para reconstruir la reverberación tardía.

Se ha desarrollado DECOR (*Deep Exponential Completion Of Room impulse responses*), una arquitectura codificador-decodificador orientada a la completación de RIR. El codificador comprime la cabecera de la RIR (2400 muestras a 48 kHz) mediante nueve bloques convolucionales con conexiones *skip* y reducción progresiva de la resolución temporal, obteniendo un vector latente de 128 dimensiones. El decodificador, guiado por un modelo físico de ruido blanco con decaimiento exponencial, estima envolventes multiexponenciales que modulan secuencias de ruido filtrado a través de un banco de diez filtros FIR en bandas de octava ISO 266. Esta formulación introduce sesgo acústico con el objetivo de reducir el tamaño del modelo preservando capacidad representacional.

La eficacia de la propuesta se ha validado mediante comparación con una arquitectura del estado del arte de tamaño considerablemente superior. Los resultados indican que DECOR alcanza un rendimiento competitivo con una complejidad sustancialmente menor, y confirman la viabilidad de la completación de RIR como estrategia práctica para la extrapolación de reverberación tardía.

Abstract

Synthesizing complete room impulse responses (RIRs) through conventional acoustic simulation is computationally demanding. This work is based on the hypothesis that the initial segment of an RIR (the first 50 ms), which contains the direct sound and early reflections, carries sufficient information about room geometry and acoustic properties to reconstruct the late reverberation tail. DECOR (*Deep Exponential Completion Of Room impulse responses*) is implemented as an encoder-decoder architecture for RIR completion. The encoder compresses the RIR head (2400 samples at 48 kHz) through nine convolutional blocks with skip connections and progressive temporal downsampling, yielding a 128-dimensional latent vector. The decoder, informed by a physical model of exponentially decaying white noise, predicts multi-exponential decay envelopes that shape filtered-noise sequences through a bank of ten FIR filters in ISO 266 octave bands. This design introduces acoustic inductive bias to reduce model size while preserving expressive capacity. The effectiveness of the approach is validated against a significantly larger state-of-the-art baseline. Results show that DECOR reaches competitive performance with substantially lower complexity, supporting the practical viability of RIR completion for late-reverberation extrapolation.

Índice

Resum	ii
Resumen	iii
Abstract	iv
Lista de figuras	vi
Lista de tablas	vii
Abreviaturas	viii
1 Introducción	1
1.1 Objetivo	1
1.2 Impacto	2
1.3 Requisitos	2
2 Fundamentos Teóricos	4
2.1 Acústica desalas	4
2.2 Audio y redes neuronales	5
3 Estado de la cuestión	6
3.1 Simulación	6
3.2 RIR Completion	8
3.3 Modelo físico	9
3.4 Transformers	10
3.5 Elección DECOR	11
4 Diseño y Arquitectura del Modelo DECOR	12
4.1 Formulación	12

4.2	El Codificador	13
4.3	Decodificador	14
4.4	Pérdida	14
5	Marco Experimental y Datasets	16
5.1	Corpus BIRD	16
5.2	Dataset sint.	17
5.3	Pipeline EDC	18
5.4	Entrenamiento	19
6	Resultados y Discusión	22
6.1	Convergencia	22
6.2	Evaluación	24
6.3	Caso cualitativo	26
7	Conclusiones y Trabajo Futuro	29
7.1	Conclusiones	29
7.2	Trabajo futuro	30
	Presupuesto y viabilidad económica	I
7.3	Costes	I
	Impacto ambiental y social	II
	Bibliography	IV

Lista de figuras

3.1	Representación conceptual del Método de Fuentes Imagen (ISM) para la simulación de reflexiones acústicas tempranas.	7
3.2	Arquitectura tipo LSTM aplicada al modelado de secuencias temporales acústicas. .	7
3.3	Concepto de <i>RIR completion</i> : extrapolación de la reverberación tardía a partir del tramo temprano de la respuesta al impulso.	8
3.4	Esquema del paradigma codificador-decodificador utilizado en tareas de extrapolación temporal de RIR.	8
3.5	Concepto de redes neuronales informadas por la física (PINNs) aplicadas al modelado acústico.	10
3.6	Arquitectura Transformer aplicada a la extrapolación de RIR: mecanismo de auto-atención que captura dependencias temporales a largo plazo en la síntesis de reverberación.	11
6.1	Evolución de la pérdida compuesta de entrenamiento y validación. Se superpone la tendencia suavizada mediante media móvil.	22
6.2	Convergencia del error absoluto medio de la Curva de Decaimiento de Energía (EDC-L1). .	23
6.3	Evolución de la norma del gradiente en escala logarítmica durante el entrenamiento. .	24
6.4	Evaluación cualitativa de un caso de estudio. (Arriba) Comparativa de la forma de onda temporal. (Centro) Espectrogramas de magnitud. (Abajo) Curvas de Decaimiento de Energía (EDC).	26

Lista de tablas

4.1	Dimensiones tensoriales de las variables principales del modelo DECOR.	13
6.1	Métricas de evaluación objetiva sobre el conjunto de test. Se reportan los valores medios obtenidos tras procesar las 40.000 muestras de evaluación.	25
6.2	Comparativa con modelos de referencia en métricas objetivas. En MSTFT se emplea flecha ascendente ($\uparrow$) para destacar que el valor del modelo propuesto es mayor que el de las referencias; en el resto de métricas, flecha descendente ($\downarrow$) indica mejor rendimiento para valores menores.	25
7.1	Resumen de costes del TFG (estimación simple)	I

Lista de abreviaturas

RIR *Room Impulse Response* — Respuesta al Impulso de Sala.

EDC *Energy Decay Curve* — Curva de Decaimiento de Energía.

DECOR *Deep Exponential Completion Of Room impulse responses* — arquitectura propuesta para completación de RIR.

BIRD *Big Impulse Response Dataset* — corpus de respuestas impulsionales empleado en la validación.

ISM *Image Source Method* — Método de Fuentes Imagen para simulación acústica.

DDSP *Differentiable Digital Signal Processing* — Procesamiento Digital de Señal Diferenciable.

MSTFT *Multi-Resolution Short-Time Fourier Transform* — pérdida espectral multirresolución.

T₆₀ Tiempo de reverberación para un decaimiento de 60 dB.

DRR *Direct-to-Reverberant Ratio* — Relación Directo-Reverberante.

FIR *Finite Impulse Response* — filtro de respuesta al impulso finita.

HRTF *Head-Related Transfer Function* — función de transferencia relacionada con la cabeza.

GPU *Graphics Processing Unit* — unidad de procesamiento gráfico.

Capítulo 1

Introducción

1.1 Objetivo

El objeto central de este Trabajo de Fin de Grado consiste en el diseño, la implementación y la validación de un modelo de aprendizaje profundo capaz de ejecutar la extrapolación temporal de la reverberación tardía (*tail*) a partir de la observación de los primeros 50 ms (*head*) de la Respuesta al Impulso de la Sala (RIR) [LGS25]. Desde una perspectiva metodológica, el problema se formula como una tarea de predicción condicionada en la que la porción temprana de la respuesta contiene la información estructural necesaria para estimar la evolución energética y espectral de la cola reverberante.

El alcance del proyecto comprende el desarrollo de tuberías de datos reproducibles, la programación de los bloques neuronales del sistema propuesto y la evaluación del rendimiento mediante métricas analíticas acústicas. Quedan expresamente fuera del alcance las optimizaciones a nivel de firmware para ejecución en sistemas embebidos de bajo consumo, así como el procesamiento geométrico tridimensional multicanal.

La memoria se articula en siete capítulos. El Capítulo 1 introduce el problema, su motivación y los requerimientos técnicos. El Capítulo 2 establece los fundamentos teóricos. El Capítulo 3 presenta el estado de la cuestión. El Capítulo 4 desarrolla el diseño y la arquitectura del modelo DECOR. El Capítulo 5 describe el marco experimental y los conjuntos de datos. El Capítulo 6 analiza los resultados y su discusión crítica. Finalmente, el Capítulo 7 recoge las conclusiones y las líneas de trabajo futuro.

1.2 Impacto

La relevancia científica y tecnológica de esta investigación se enmarca en el crecimiento del audio inmersivo para Realidad Virtual (VR) y Realidad Aumentada (AR), ámbitos en los que la caracterización acústica del recinto condiciona de forma directa la plausibilidad perceptual de la escena sonora. Los métodos tradicionales de simulación, como el Método de Fuentes Imagen (ISM) o el trazado de rayos, presentan un coste computacional elevado que crece de manera muy acusada con la duración de la cola reverberante, lo que limita su uso en escenarios con exigencias temporales estrictas.

El impacto esperado se establece en tres dimensiones complementarias. En el plano técnico, se persigue una reducción drástica del tiempo de inferencia mediante un paradigma de procesamiento de señal diferenciable orientado a síntesis eficiente. En el plano acústico, se pretende preservar verosimilitud física al incorporar restricciones teóricas en el decodificador, de modo que la señal estimada respete patrones de decaimiento compatibles con la física del recinto. En el plano aplicado, el sistema presenta potencial de transferencia como herramienta de aumento de datos para sistemas de reconocimiento de voz, al permitir generar colas reverberantes plausibles en volumen elevado y coste operativo reducido.

1.3 Requisitos

Las especificaciones del sistema se formulan bajo criterios medibles y verificables, de acuerdo con principios de ingeniería de sistemas orientados a trazabilidad experimental y validación cuantitativa.

- **Requerimientos de Entrada/Salida de Señal**

- Procesamiento monoaural con frecuencia de muestreo estricta de 48 kHz.
- Ventana de entrada acotada a $N_{head} = 2400$ muestras.
- Horizonte de predicción de cola fijado en $N_{tail} = 45600$ muestras.

- **Requerimientos de Coherencia Acústica**

- Conservación de continuidad energética entre cabeza y cola sintetizada.
- Error absoluto medio (MAE) acotado sobre la curva EDC.
- Desajustes controlados en métricas físicas de referencia T_{60} y DRR.

- **Requerimientos del Ciclo de Entrenamiento**

- Estabilidad numérica absoluta, con ausencia de valores NaN o Inf.
- Repetibilidad experimental mediante fijación estricta de semillas pseudoaleatorias.
- Mecanismos automatizados de *checkpointing* basados en minimización de pérdida de validación.

- **Requerimientos de Ejecución y Cómputo**

- Adecuación de las rutinas de optimización masiva a entornos en la nube con GPU de alta gama.
- Tiempo de inferencia de la red predictiva varios órdenes de magnitud inferior al de un simulador físico geométrico convencional.

Capítulo 2

Fundamentos Teóricos

2.1 Acústica desalas

La Respuesta al Impulso de la Sala, denotada como $h(t)$, constituye la caracterización completa del comportamiento acústico de un recinto cuando este se modela como un sistema Lineal Invariante en el Tiempo (LTI). Bajo dicho marco, $h(t)$ representa la salida del sistema ante una excitación impulsiva ideal y, en consecuencia, encapsula tanto los mecanismos de propagación directa como los procesos de reflexión en fronteras materiales. Desde una perspectiva fenomenológica, la respuesta temporal se descompone en tres contribuciones: sonido directo, reflexiones tempranas (*early reflections*) y reverberación tardía (*late reverberation*).

El concepto de tiempo de mezcla, t_{mix} , establece el umbral físico a partir del cual la densidad temporal de reflexiones se vuelve suficientemente alta como para que el campo acústico transite hacia un régimen difuso y de naturaleza estocástica [Kut16]. Antes de dicho instante, las reflexiones mantienen una estructura temporal relativamente resoluble y conservan información geométrica macroscópica del recinto; después de t_{mix} , la superposición densa de trayectorias reduce la interpretabilidad determinista individual de cada reflexión. En práctica de ingeniería acústica, este umbral se sitúa típicamente en el entorno de los primeros 50 ms, lo que respalda la viabilidad de inferir o extrapolar la cola reverberante a partir del segmento temprano de la RIR.

Dado que la reverberación tardía presenta un carácter estocástico, su análisis resulta más robusto cuando se formula en términos energéticos. En este contexto, se adopta la Curva de Decaimiento de Energía (EDC) según la formulación de Schroeder [Sch65]:

$$EDC(t) = \frac{\int_t^\infty h^2(\tau) d\tau}{\int_0^\infty h^2(\tau) d\tau} \quad (2.1)$$

donde $h(\tau)$ es la respuesta al impulso del recinto en función del tiempo, τ es la variable temporal de integración y t es el instante a partir del cual se evalúa la energía remanente. El denominador normaliza la magnitud respecto de la energía total de la respuesta.

2.2 Audio y redes neuronales

El modelado de audio en bruto constituye un problema de alta complejidad debido a la elevada dimensionalidad de las señales temporales y a su marcada sensibilidad a variaciones de fase. En este contexto, la literatura de aprendizaje profundo introduce el concepto de espacio latente como representación comprimida de los factores relevantes de los datos [GBC16]. Bajo esta formulación, un codificador se entiende como una transformación no lineal que proyecta observaciones de alta dimensión a una representación compacta:

$$f_{\theta} : \mathcal{X} \rightarrow \mathcal{Z}, \quad \mathbf{z} = f_{\theta}(\mathbf{x}), \quad \mathbf{z} \in \mathbb{R}^d. \quad (2.2)$$

Aquí, $\mathbf{x}$ denota la secuencia de audio de entrada y $\mathbf{z}$ el vector latente que abstrae propiedades acústicas fundamentales del fenómeno observado, reduciendo redundancias y preservando la información estructural necesaria para la síntesis posterior.

Desde el punto de vista generativo, la predicción directa de la forma de onda, muestra a muestra, presenta inestabilidades en el dominio temporal asociadas a la naturaleza altamente oscilatoria de la señal y a la acumulación de error local. Como alternativa, la síntesis paramétrica desplaza el problema desde la generación explícita de cada muestra hacia la estimación de parámetros de control. Este principio queda formalizado en el marco de Procesamiento Digital de Señal Diferenciable (DDSP) [Eng+20], donde la red neuronal no actúa como sintetizador final de audio, sino como estimador de parámetros que gobiernan bloques DSP deterministas, tales como osciladores, generadores de ruido o filtros.

La incorporación de sesgo inductivo físico en la arquitectura proporciona una ventaja metodológica decisiva frente a modelos de caja negra puros. Al integrar elementos acústicamente interpretables, como filtros FIR y curvas de decaimiento exponencial, directamente en el grafo computacional diferenciable del decodificador, el espacio de soluciones admisibles queda restringido a trayectorias consistentes con el comportamiento físico esperado de la reverberación. Esta restricción estructural reduce la ambigüedad del aprendizaje, mejora la estabilidad del entrenamiento y favorece la generalización fuera de la muestra frente a formulaciones completamente no informadas físicamente.

Capítulo 3

Estado de la cuestión

La caracterización acústica de recintos mediante la Respuesta al Impulso de la Sala (RIR) ha sido históricamente un desafío computacional. Esta sección revisa las metodologías actuales, desde los modelos de procesamiento de señal hasta las arquitecturas informadas por la física que definen el estado de la cuestión en la extrapolación acústica.

3.1 Simulación

Históricamente, la simulación de la acústica de salas para generar Respuestas al Impulso de la Sala (RIR) se ha abordado mediante técnicas de acústica geométrica. Entre los enfoques más consolidados y utilizados se encuentran el método de fuentes imagen (*Image Source Method*, ISM) [AB79] y el trazado de rayos (*Ray Tracing*). Estos métodos calculan la propagación del sonido modelando las reflexiones (tanto especulares como difusas) que ocurren al interactuar las ondas sonoras con las superficies del recinto.

Sin embargo, estas técnicas puramente físicas presentan un desafío crítico: su coste computacional escala de forma lineal (e incluso exponencial en el caso de ISM para órdenes altos de reflexión) con la duración de la respuesta al impulso que se desea simular. Esto hace que la generación de colas de reverberación largas y densas sea un proceso prohibitivo en términos de tiempo, limitando su viabilidad para aplicaciones en tiempo real o para la creación de bases de datos masivas.




Figura 3.1: Representación conceptual del Método de Fuentes Imagen (ISM) para la simulación de reflexiones acústicas tempranas.

Para superar estas barreras computacionales, en los últimos años se ha introducido el aprendizaje profundo (*Deep Learning*) como modelo sustituto (*surrogate model*) capaz de acelerar drásticamente la predicción acústica. Estos modelos están diseñados para aprender las complejas relaciones no lineales que existen entre las propiedades físicas de un recinto y su respuesta acústica resultante.

Un ejemplo destacado de esta transición es el uso de arquitecturas secuenciales, como las redes de Memoria a Corto y Largo Plazo (LSTM), que han demostrado ser altamente eficaces para predecir las Curvas de Decaimiento de Energía (EDC). A partir de parámetros de entrada relativamente simples, como las dimensiones geométricas de la sala y los coeficientes de absorción de sus materiales, estas redes logran estimar la curva EDC con una precisión comparable a los métodos tradicionales, pero con un coste computacional fraccionario [MS25]. Este avance sienta las bases para arquitecturas más complejas capaces de predecir la señal de audio completa en el dominio del tiempo.




Figura 3.2: Arquitectura tipo LSTM aplicada al modelado de secuencias temporales acústicas.

3.2 RIR Completion

Una de las áreas más innovadoras en la acústica computacional reciente es la tarea denominada “*RIR completion*” o completado de la respuesta al impulso. Este enfoque se aleja de la generación de señales desde cero y se centra en la extrapolación temporal de una respuesta existente pero incompleta.




Figura 3.3: Concepto de *RIR completion*: extrapolación de la reverberación tardía a partir del tramo temprano de la respuesta al impulso.

La hipótesis física fundamental que sustenta este paradigma postula que el sonido directo y las reflexiones tempranas —que comprenden aproximadamente los primeros 50 ms de una RIR— encapsulan información latente suficiente sobre las propiedades macroscópicas del recinto. Específicamente, este segmento inicial contiene las huellas geométricas de las superficies más próximas y los coeficientes de absorción de los materiales principales. Desde un punto de vista acústico, la reverberación tardía no es un fenómeno estocástico independiente, sino la consecuencia determinista de la evolución de esas reflexiones tempranas hacia un campo difuso.

Para explotar esta relación, se han propuesto arquitecturas basadas en el paradigma codificador-decodificador (*encoder-decoder*). El modelo DECOR (*Deep room impulse response completion*) es un exponente de esta tendencia. En este sistema, un codificador convolucional profundo (**DecorEncoder**) comprime la estructura temporal y espectral de los primeros 50 ms en un vector latente de baja dimensión. Posteriormente, un decodificador (**DecorDecoder**) utiliza este vector para parametrizar un modelo físico de decaimiento exponencial por bandas de octava.




Figura 3.4: Esquema del paradigma codificador-decodificador utilizado en tareas de extrapolación temporal de RIR.

La principal ventaja de este método es la eficiencia: mientras que los simuladores geométricos convencionales deben trazar miles de rayos para modelar la cola de la respuesta, estos modelos basados en aprendizaje profundo pueden sintetizar reverberaciones realistas de forma casi instantánea. Esto permite generar entornos acústicos complejos con una fracción del coste computacional de los métodos clásicos, facilitando aplicaciones en realidad virtual y aumento de datos para entrenamiento de sistemas de reconocimiento de voz.

3.3 Modelo físico

El éxito y la capacidad de generalización de los modelos de aprendizaje profundo en la acústica de salas dependen fundamentalmente de la disponibilidad de bases de datos extensas y diversas. Entrenar redes neuronales para que comprendan la propagación del sonido requiere exponerlas a una multitud de geometrías, materiales y posiciones de fuente-receptor.

En este contexto, el *Big Impulse Response Dataset* (BIRD) [Gro+20] representa un avance fundamental para la comunidad investigadora. Al proporcionar decenas de miles de respuestas impulsionales de alta calidad simuladas y medidas bajo una amplia variedad de condiciones acústicas, BIRD permite entrenar arquitecturas complejas evitando el sobreajuste (*overfitting*) que ocurre cuando se utilizan conjuntos de datos limitados.

Paralelamente a la evolución de los datos, la metodología de modelado ha experimentado un cambio de paradigma. La investigación más reciente tiende a alejarse de los modelos puramente estadísticos o de "caja negra", que aprenden mapeos directos entre entrada y salida sin restricciones físicas, para adoptar modelos híbridos o Redes Neuronales Informadas por la Física (PINNs, por sus siglas en inglés).

Como demuestran trabajos recientes [Kar+24b], la integración de ecuaciones diferenciales parciales (como la ecuación de onda tridimensional) directamente en la función de pérdida durante el entrenamiento obliga a la red a generar predicciones que no solo son estadísticamente probables, sino físicamente coherentes. Este enfoque ha demostrado ser especialmente superior en el modelado de bajas frecuencias, donde los fenómenos ondulatorios como la difracción y los modos propios de la sala dominan la respuesta y provocan que los métodos de acústica geométrica tradicionales fallen. Herramientas de código abierto como RIRPINN [Kar+24a] han facilitado la adopción de estas técnicas, permitiendo a la comunidad integrar el conocimiento físico en el ciclo de desarrollo del aprendizaje profundo.




Figura 3.5: Concepto de redes neuronales informadas por la física (PINNs) aplicadas al modelado acústico.

3.4 Transformers

La evolución de las arquitecturas de aprendizaje profundo aplicadas a series temporales y acústica ha trascendido el uso exclusivo de Redes Neuronales Convolucionales (CNN) y Recurrentes (RNN). Recientemente, la arquitectura *Transformer*, que originalmente revolucionó el procesamiento del lenguaje natural, se ha adaptado para modelar fenómenos físicos complejos y sistemas dinámicos continuos.

La fortaleza de los *Transformers* reside en su mecanismo de auto-atención (*self-attention*), que permite a la red ponderar la importancia relativa de diferentes instantes de tiempo en una secuencia, independientemente de la distancia temporal que los separe. Este mecanismo es especialmente valioso para capturar dependencias temporales de largo alcance en sistemas dinámicos no lineales, permitiendo que la red establezca relaciones causales entre eventos acústicos distantes en el tiempo.

La extracción rigurosa de la señal de audio se realiza mediante un proceso de decodificación secuencial. Dado un vector latente $\mathbf{z}$ comprimido por el codificador, el decodificador *Transformer* genera iterativamente muestras de audio mediante predicción autoregresiva. En cada paso de tiempo t , el modelo calcula la distribución de probabilidad $p(x_t | x_{<t}, \mathbf{z})$ sobre las posibles amplitudes, condicionada por el historial de muestras previas $x_{<t}$ y el contexto acústico $\mathbf{z}$. La estabilidad numérica y coherencia temporal se mantiene gracias al mecanismo de atención, que asegura que cada muestra generada se ajuste de forma coherente al decaimiento energético esperado de la reverberación.

Aplicado a la extrapolación de la RIR, el *Transformer* permite extraer una "física latente" a partir

de las reflexiones tempranas. Al procesar el tramo inicial de la respuesta, la red aprende patrones de decaimiento que se propagan consistentemente durante toda la síntesis de la cola, garantizando que la reverberación generada mantenga integridad acústica y mantiene la coherencia perceptual con el recinto original.




Figura 3.6: Arquitectura Transformer aplicada a la extrapolación de RIR: mecanismo de auto-atención que captura dependencias temporales a largo plazo en la síntesis de reverberación.

3.5 Elección DECOR

La elección de DECOR en este trabajo se justifica por el equilibrio que ofrece entre fidelidad física, coste computacional y viabilidad práctica de implementación. Frente a enfoques puramente geométricos, DECOR reduce drásticamente el tiempo de inferencia al predecir la reverberación tardía a partir de los primeros 50 ms, manteniendo una representación acústicamente coherente del recinto. Frente a modelos totalmente de caja negra, su formulación codificador-decodificador con decaimiento por bandas introduce una estructura inductiva alineada con la física de la reverberación, mejorando la interpretabilidad y la robustez. Además, su planteamiento encaja de forma directa con la disponibilidad de datasets grandes como BIRD y con el objetivo aplicado de este TFG: extrapolar colas de RIR realistas de forma eficiente para tareas de síntesis acústica y aumento de datos.

Capítulo 4

Diseño y Arquitectura del Modelo DECOR

Este capítulo presenta la formulación matemática y el diseño arquitectónico del modelo DECOR [LGS25], concebido como una solución eficiente para la extrapolación de respuestas al impulso de recinto a partir de observaciones parciales de corta duración.

4.1 Formulación

La señal acústica continua se discretiza a frecuencia de muestreo $f_s = 48$ kHz, obteniéndose la secuencia temporal discreta $h[n]$. El problema de completación de RIR se formula bajo el supuesto de observación parcial del tramo temprano de la respuesta. En particular, se define un índice de truncamiento fijo $N_{head} = 2400$ muestras, correspondiente a una ventana temporal de 50 ms.

Bajo esta partición, el vector de entrada se define como $\mathbf{x} \in \mathbb{R}^{2400}$, conteniendo el sonido directo y las reflexiones tempranas. El objetivo supervisado se define como el vector de cola reverberante $\mathbf{y} \in \mathbb{R}^{45600}$, asociado a los 950 ms restantes de la respuesta discreta.

El sistema DECOR se modela como un mapeo parametrizado $\mathcal{F}_\Theta : \mathbb{R}^{2400} \rightarrow \mathbb{R}^{45600}$, donde Θ denota el conjunto de parámetros entrenables. Su estructura interna se descompone en un codificador $\mathcal{E}_\psi$ y un decodificador $\mathcal{D}_\phi$:

$$\mathbf{z} = \mathcal{E}_\psi(\mathbf{x}), \quad \hat{\mathbf{y}} = \mathcal{D}_\phi(\mathbf{z}) = \mathcal{D}_\phi(\mathcal{E}_\psi(\mathbf{x})), \quad \Theta = \{\psi, \phi\}. \quad (4.1)$$

Tabla 4.1: Dimensiones tensoriales de las variables principales del modelo DECOR.

Componente	Símbolo Matemático	Dimensionalidad Tensorial
Cabeza de la RIR (Entrada)	$\mathbf{x}$	(1×2400)
Vector Latente	$\mathbf{z}$	(1×128)
Cola Sintetizada (Salida)	$\hat{\mathbf{y}}$	(1×45600)

4.2 El Codificador

La unidad elemental del codificador corresponde a un bloque convolucional residual. Para una entrada $\mathbf{h}_{in}$, la salida del bloque se define como

$$\mathbf{h}_{out} = \sigma(\mathcal{F}_{main}(\mathbf{h}_{in}) + \mathcal{F}_{skip}(\mathbf{h}_{in})). \quad (4.2)$$

En esta expresión, $\mathcal{F}_{main}$ denota una convolución unidimensional con tamaño de núcleo 15, salto 2 y relleno simétrico orientado a conservar coherencia dimensional local, seguida de normalización por lotes (*Batch Normalization*). Por su parte, $\mathcal{F}_{skip}$ representa la rama residual con convolución 1×1 y el mismo salto, con el fin de alinear la dimensionalidad de los tensores antes de la suma elemento a elemento. La no linealidad σ se implementa mediante una activación Parametric ReLU (PReLU).

La arquitectura completa de *DecorEncoder* se organiza como una cascada de 9 bloques residuales. La jerarquía de canales sigue la progresión

$$1 \rightarrow 16 \rightarrow 32 \rightarrow 64 \rightarrow 128 \rightarrow 256 \rightarrow 512 \rightarrow 512 \rightarrow 512 \rightarrow 512. \quad (4.3)$$

La aplicación sucesiva de salto 2 en cada bloque produce un factor de reducción temporal global igual a $2^9 = 512$. En consecuencia, la entrada original $\mathbf{x} \in \mathbb{R}^{1 \times 2400}$ experimenta una compresión pronunciada sobre el eje temporal, mientras la información acústica se redistribuye en la profundidad de los mapas de características.

Tras el último bloque convolucional, la salida se somete a una agrupación promedio global adaptativa (*Adaptive Average Pooling*), operación que colapsa la dimensión temporal residual y entrega un vector denso de 512 componentes. Finalmente, una transformación lineal proyecta dicho vector al embedding latente

$$\mathbf{z} \in \mathbb{R}^{128}, \quad (4.4)$$

el cual recoge la firma acústica de las reflexiones tempranas en una representación compacta apta para la etapa de síntesis de cola reverberante.

4.3 Decodificador

La síntesis de la cola reverberante estimada se rige por el siguiente modelo físico:

$$\hat{r}(t) = \sum_{m=1}^M \left(\sum_{k=1}^K A_{m,k} \cdot e^{-b_k(t_0+t)} \right) w_m(t) \quad (4.5)$$

donde $M = 10$ denota el número de bandas de octava bajo la norma ISO 266, $K = 20$ el número de tasas de decaimiento linealmente combinadas, $t_0 = 0.05$ s el instante de transición temporal correspondiente al inicio de la cola, y $w_m(t)$ el ruido blanco gaussiano filtrado asociado a la banda espectral m .

El estimador paramétrico inicial opera sobre el vector latente $\mathbf{z} \in \mathbb{R}^{128}$ mediante un perceptrón multicapa compuesto por 7 capas densas encadenadas, cada una con 512 unidades y activación LeakyReLU con pendiente de zona muerta $\alpha = 0.2$. La etapa de salida adopta un esquema ramificado (*multi-head*): una rama produce amplitudes base $A'_{m,k}$ y la otra produce coeficientes de enmascaramiento $C'_{m,k}$. La activación efectiva se obtiene por producto de Hadamard, con enmascaramiento sigmoideal, según $A_{m,k} = A'_{m,k} \odot \sigma(C'_{m,k})$.

Las tasas de amortiguamiento b_k se establecen sobre una escala log-uniforme vinculada a tiempos de reverberación T_{60} dentro del intervalo físico $[0.05, 3.0]$ s. Este criterio impone una restricción acústica inicial coherente con recintos reales y, al mismo tiempo, conserva flexibilidad, puesto que los b_k se tratan como parámetros libres optimizables durante el aprendizaje del modelo.

La etapa de coloración espectral utiliza un banco de 10 filtros FIR de fase lineal y orden 1023, calculados de forma analítica mediante diseño por ventanas con la función `firwin` de SciPy. Dicho banco separa la señal estocástica en bandas de octava normalizadas. Finalmente, una convolución unidimensional de tamaño de núcleo 1 recibe los 10 canales filtrados y ejecuta una suma ponderada optimizable, equivalente a una transformación lineal 1×1 , para reducir la representación multibanda a un único canal mono que constituye la cola extendida final.

4.4 Pérdida

La optimización directa sobre la forma de onda mediante Error Cuadrático Medio (MSE) resulta subóptima en tareas de síntesis de audio reverberante. En particular, el MSE presenta elevada

sensibilidad ante desajustes de fase que pueden ser perceptualmente poco relevantes, y no representa con fidelidad la respuesta auditiva humana, que depende de la distribución espectral de energía en el tiempo con mayor peso que del error puntual muestra a muestra.

Con el objetivo de ajustar el aprendizaje a criterios más cercanos a la percepción, se establece la pérdida de Transformada de Fourier a Corto Plazo multirresolución (MSTFT). Para una respuesta predicha $\hat{h}$ y una respuesta de referencia h , la pérdida total se define como

$$\mathcal{L}_{\text{MSTFT}}(\hat{h}, h) = \sum_{r=1}^R \left(L_{sc}^{(r)} + L_{sm}^{(r)} \right). \quad (4.6)$$

El término de convergencia espectral en la resolución r se expresa mediante norma de Frobenius como

$$L_{sc}^{(r)} = \frac{\left\| \left| \text{STFT}_r(\hat{h}) \right| - \left| \text{STFT}_r(h) \right| \right\|_F}{\left\| \left| \text{STFT}_r(h) \right| \right\|_F + \epsilon}. \quad (4.7)$$

El término de log-magnitud espectral se formula como

$$L_{sm}^{(r)} = \left\| \log \left(\left| \text{STFT}_r(\hat{h}) \right| + \epsilon \right) - \log \left(\left| \text{STFT}_r(h) \right| + \epsilon \right) \right\|_1. \quad (4.8)$$

En estas expresiones, ϵ es un término de estabilidad numérica. La presencia del logaritmo en $L_{sm}^{(r)}$ aproxima la sensibilidad psicoacústica a variaciones relativas de presión sonora, lo que favorece un ajuste más coherente con la percepción auditiva.

En el modelo presentado se emplean $R = 4$ resoluciones, con ventanas de Hann de tamaños $W \in \{64, 512, 2048, 8192\}$ y saltos proporcionales $H \in \{32, 256, 1024, 4096\}$. Esta selección combina escalas temporales cortas, adecuadas para transitorios rápidos, con escalas largas que mejoran la precisión frecuencial en el modelado de modos estacionarios y del decaimiento macroscópico de la reverberación tardía.

Capítulo 5

Marco Experimental y Datasets

Este capítulo expone el entorno experimental, las tuberías de procesamiento de datos (*data pipelines*) y las estrategias de optimización empleadas durante el entrenamiento del sistema. Su propósito es establecer, con precisión metodológica, el marco empírico sobre el que se sustenta la validación del modelo propuesto.

5.1 Corpus BIRD

El *Big Impulse Response Dataset* (BIRD) [Gro+20] constituye el corpus principal empleado en este trabajo. Una de las aportaciones más relevantes del estudio reside en la evaluación, por primera vez en la literatura, de la arquitectura DECOR sobre este corpus masivo. Esta decisión metodológica reviste especial interés científico, puesto que la notable diversidad geométrica, material y espacial presente en BIRD somete al modelo a un escenario de validación considerablemente más exigente que el de los bancos sintéticos acotados habitualmente utilizados en estudios preliminares. En consecuencia, la exposición del sistema a dicha variabilidad permite examinar con mayor rigor su capacidad de generalización acústica.

Desde el punto de vista operativo, el corpus se organiza en subconjuntos o *folds*, cada uno de ellos asociado a agrupaciones independientes de respuestas impulsionales. Los archivos de audio son sometidos a una secuencia estricta de adecuación previa a su uso por la red neuronal. En primer lugar, cada señal se transforma a formato monoaural, tras lo cual se remuestrea a una frecuencia uniforme de 48 kHz. A continuación, se realiza una alineación temporal con respecto al pico máximo de amplitud, con el objetivo de garantizar que el transitorio correspondiente al sonido directo ocupe un índice determinista dentro de la secuencia. Esta operación resulta crítica para homogeneizar la referencia temporal entre impulsos acústicamente distintos.

Posteriormente, cada respuesta se normaliza en amplitud y se ajusta a una longitud fija de 48.000 muestras, equivalentes a 1 segundo de duración. Una vez establecida esta longitud de referencia, la señal se segmenta en dos regiones: una cabeza temprana de longitud $N_{head} = 2400$ muestras y una cola reverberante remanente. Esta partición permite aislar, por un lado, la porción que contiene el sonido directo y las reflexiones tempranas y, por otro, la región que concentra el proceso de decaimiento tardío que el sistema debe estimar.

La división entre entrenamiento y validación no se efectúa de manera aleatoria a nivel de impulso individual, sino a nivel de *folds*. Esta decisión responde a la necesidad de evitar fuga de datos (*data leakage*), fenómeno que conduciría a una sobreestimación artificial del rendimiento si señales pertenecientes a un mismo entorno acústico apareciesen repartidas simultáneamente entre ambos subconjuntos. Al establecer la separación por agrupaciones de salas independientes, se garantiza que la evaluación se lleve a cabo sobre recintos no observados durante el ajuste de pesos, lo que proporciona una estimación más fiable de la capacidad de generalización del modelo.

5.2 Dataset sint.

Con objeto de disponer de un entorno de control plenamente trazable, se generó un corpus sintético propio compuesto por 6000 recintos rectangulares. Este subconjunto no pretende sustituir la diversidad geométrica y material del corpus principal, sino proporcionar un banco de simulación pura en el que todas las variables relevantes quedan explícitamente determinadas. Tal circunstancia resulta especialmente valiosa para estudios de ablación y para la verificación de la consistencia física de la tubería de datos antes del inicio de las rutinas de aprendizaje.

La obtención de las respuestas impulsionales sintéticas se apoya en el Método de Fuentes Imagen (ISM), según la formulación clásica de [AB79], mediante su implementación en el entorno de código abierto *Pyroomacoustics*. Bajo este marco, las dimensiones tridimensionales del recinto, las coordenadas de la fuente acústica y del receptor, así como los coeficientes de absorción de las superficies, se determinan por muestreo aleatorio dentro de intervalos físicamente realistas. De esta manera, se obtiene un conjunto amplio de escenas acústicas artificiales con control explícito de sus parámetros geométricos y materiales.

La tubería operativa programada en el script `scripts/generate_synthetic_rir_dataset.py` produce y almacena, para cada muestra, cuatro artefactos en formato binario `.npy`: la RIR completa, la sección de cabeza correspondiente a los primeros 50 ms, la sección de cola asociada a los 950 ms restantes y la curva EDC derivada de dicha cola. De forma complementaria, las propiedades macroscópicas y los descriptores globales de cada recinto, entre ellos las dimensiones geométricas y

el T_{60} estimado, se recogen de manera centralizada en un archivo tabular indexado denominado `metadata.csv`.

El control de calidad del conjunto sintético se lleva a cabo mediante el script `scripts/validate_generated_dataset.py`, cuya función consiste en actuar como filtro de sanidad analítica previo al entrenamiento. Esta rutina audita de forma sistemática los rangos geométricos admisibles, la coherencia espacial de las trayectorias fuente-receptor y la validez física del tiempo de reverberación calculado. Mediante este procedimiento se favorece la exclusión temprana de anomalías numéricas, artefactos de simulación o muestras incompatibles con los supuestos acústicos del problema.

5.3 Pipeline EDC

Durante la tubería de datos, el cálculo de la Curva de Decaimiento de Energía (EDC) se establece como métrica de control físico para evaluar la coherencia del decaimiento reverberante. Para la cola discreta $y[n]$ de longitud N , se emplea la forma discreta de Schroeder:

$$\text{EDC}_{\text{norm}}[t] = \frac{\sum_{n=t}^{N-1} y[n]^2}{\sum_{n=0}^{N-1} y[n]^2} \quad (5.1)$$

donde $y[n]$ representa la secuencia discreta de la cola reverberante. Esta normalización garantiza una trayectoria monótona decreciente acotada en el intervalo $[0, 1]$, con valor unitario al inicio del decaimiento y aproximación asintótica a cero para tiempos tardíos.

Con el fin de obtener una escala de análisis perceptualmente adecuada, la curva normalizada se expresa en decibelios mediante transformación logarítmica:

$$\text{EDC}_{dB}[t] = 10 \log_{10} (\max(\text{EDC}_{\text{norm}}[t], \epsilon)) \quad (5.2)$$

El término de protección ϵ , asociado en práctica a un suelo dinámico del orden de -80 dB, resulta indispensable para preservar estabilidad numérica en el cálculo tensorial, evitando singularidades cuando la energía remanente tiende a cero.

Desde la perspectiva computacional, la lógica de segmentación temporal (corte exacto en la muestra 2400) y el cálculo de la EDC se implementan dentro de estructuras de carga iterativa (*DataLoaders*). Este diseño permite generar tensores de manera dinámica y empaquetarlos en lotes (*batches*), manteniendo un flujo de memoria estable hacia GPU sin colapso de memoria principal. De forma simultánea, se conserva la trazabilidad exacta entre la cabeza de entrada, la cola objetivo y su EDC

analítica en cada muestra procesada.

5.4 Entrenamiento

El proceso de optimización se ejecutó en la plataforma Google Colab Pro, con uso de aceleradores gráficos NVIDIA A100, requisito operativo para el tratamiento eficiente de secuencias temporales extensas en dominio de audio. Para la evaluación del comportamiento fuera de muestra se adoptó una estrategia de validación cruzada (*k-fold cross-validation*), estableciendo particiones con proporción de 3 *folds* dedicados a la fase de aprendizaje y 1 *fold* reservado para evaluación cruzada.

La dinámica de ajuste de parámetros se rige por una función de coste compuesta:

$$\mathcal{L}_{total} = \beta \cdot \mathcal{L}_{MSTFT} + \alpha \cdot \mathcal{L}_{EDC-L1} \quad (5.3)$$

Esta formulación combina el error espectral multiresolución, ponderado por β , con el error absoluto asociado a la curva de decaimiento energético temporal, ponderado por α . Dentro del protocolo de validación, la métrica *L1* sobre la EDC se establece como indicador principal para verificar la precisión física de la respuesta sintetizada durante el ciclo iterativo de aprendizaje.

Para la actualización de pesos se emplea el optimizador Ranger21, diseñado para trayectorias de optimización prolongadas y robustas. Este algoritmo incorpora mecanismos de estabilización, entre ellos el recorte de gradientes (*Gradient Clipping*), que permite mitigar el riesgo de explosión de gradientes característico en la predicción de secuencias largas. Asimismo, contempla una fase final de enfriamiento (*Cooldown*) que reduce progresivamente la tasa de aprendizaje en las últimas épocas, favoreciendo la aproximación estable hacia mínimos profundos de la superficie de coste.

El protocolo de entrenamiento se estructura en tres fases claramente diferenciadas:

1. **Fase 1 (Épocas 1 a 20) — Inicialización Frecuencial.** El entrenamiento se inició con un tamaño de lote de 128 muestras y una tasa de aprendizaje de $1 \cdot 10^{-4}$. En esta etapa se establecieron los pesos de la función de coste como $\alpha = 0.0$ y $\beta = 1.0$. El propósito consistió en permitir que la red asimilara la estructura espectral de la cola reverberante sin imponer todavía penalización temporal explícita, favoreciendo un asentamiento inicial de los parámetros del decodificador. Al cierre de esta fase se obtuvo una pérdida de validación (Val Loss) de 11.13 y un error EDC-L1 preliminar de 0.10.

Listing 5.1: Ejecución de entrenamiento correspondiente a la Fase 1.

```
DATA_LOCAL="/content/BIRD_Local"
```

```
CHECKPOINT_DRIVE="/content/drive/MyDrive/BIRD_Dataset/decor_best_model.pth"

!python scripts/train.py \
    --data-root "$DATA_LOCAL" \
    --epochs 20 \
    --batch-size 128 \
    --lr 1e-4 \
    --num-workers 8 \
    --checkpoint "$CHECKPOINT_DRIVE"
```

2. **Fase 2 (Épocas 21 a 400) — Estabilización Transitoria y Acoplamiento Físico.** La transición hacia la optimización conjunta mostró una inestabilidad intensa cuando se activó de forma abrupta la penalización temporal con $\alpha = 0.1$, observándose explosión de la norma del gradiente y aumento de la pérdida por encima de 19. Para mitigar este comportamiento se aplicó una estrategia progresiva: la tasa de aprendizaje se redujo a $1 \cdot 10^{-5}$ y el término temporal se suavizó inicialmente a $\alpha = 0.01$, elevándolo de manera gradual hasta 0.05. De forma complementaria, el tamaño de lote se amplió a 256 muestras para aprovechar la capacidad de cómputo de los aceleradores gráficos y disminuir la varianza estocástica del gradiente. Bajo este esquema el optimizador absorbió la nueva restricción y, en la época 390, se superó la barrera de pérdida con una Val Loss de 9.41 y un error EDC-L1 de 0.085.

Listing 5.2: Ejecución de entrenamiento correspondiente a la Fase 2.

```
!python scripts/train.py \
    --data-root "$DATA_LOCAL" \
    --epochs 400 \
    --batch-size 256 \
    --lr 1e-4 \
    --loss-alpha 0.05 \
    --loss-beta 1.0 \
    --num-workers 8 \
    --resume "$CHECKPOINT_PREVIO" \
    --checkpoint "$NUEVO_CHECKPOINT"
```

3. **Fase 3 (Épocas 401 a 590) — Afinación Fina y Convergencia Asintótica.** En la etapa final se mantuvieron fijos el tamaño de lote en 256 y el peso temporal en $\alpha = 0.05$, operando con una tasa de aprendizaje conservadora de $1 \cdot 10^{-5}$ para recorrer el entorno del mínimo con mayor precisión. La fase de enfriamiento (*Cooldown*) de Ranger21 resultó determinante en

este tramo, promoviendo el asentamiento definitivo de los pesos y una convergencia estable. En la iteración terminal se extrajo el punto de control óptimo (*checkpoint*), registrándose un mínimo absoluto histórico con Val Loss de 9.345, resultado que respalda la eficacia del protocolo de entrenamiento.

Listing 5.3: Ejecución de entrenamiento correspondiente a la Fase 3 (pulido final).

```
!python scripts/train.py \  
    --data-root "$DATA_LOCAL" \  
    --epochs 590 \  
    --batch-size 256 \  
    --lr 1e-5 \  
    --loss-alpha 0.05 \  
    --loss-beta 1.0 \  
    --num-workers 8 \  
    --resume "$CHECKPOINT_PREVIO" \  
    --checkpoint "$NUEVO_CHECKPOINT"
```

Capítulo 6

Resultados y Discusión

6.1 Convergencia

El proceso de optimización se extendió a lo largo de 590 épocas, observándose un régimen de estabilización asintótica en el tramo final. La evolución de la función de coste compuesta (MSTFT + EDC) muestra un descenso sostenido y coherente entre entrenamiento y validación. Tal como se aprecia en la Figura 6.1, la curva de validación sigue de manera estrecha la trayectoria de entrenamiento y se mantiene en valores equivalentes o inferiores, alcanzando niveles en el entorno de 9.42. Este patrón descarta de forma consistente la presencia de sobreajuste (*overfitting*) y respalda la capacidad de generalización del modelo ante recintos no observados. Las oscilaciones de alta frecuencia, visibles tras superponer una tendencia suavizada por media móvil, se interpretan como un efecto inherente a la sensibilidad paramétrica de arquitecturas de Procesamiento Digital de Señal Diferenciable (DDSP).




Figura 6.1: Evolución de la pérdida compuesta de entrenamiento y validación. Se superpone la tendencia suavizada mediante media móvil.

La métrica física principal, definida como error absoluto medio sobre la Curva de Decaimiento

de Energía (EDC-L1), presenta convergencia robusta durante el entrenamiento. En particular, la trayectoria perfora el umbral de 0.10 y se consolida en torno a 0.08 en las épocas finales, tal como se observa en la Figura 6.2. Este comportamiento confirma que la red no solo reduce error espectral, sino que también preserva la dinámica energética del decaimiento reverberante con precisión físicamente consistente.




Figura 6.2: Convergencia del error absoluto medio de la Curva de Decaimiento de Energía (EDC-L1).

Desde la perspectiva de estabilidad numérica, la predicción de tasas de decaimiento exponencial b_k en el decodificador induce una superficie de pérdida fuertemente no convexa. La monitorización de la norma del gradiente, representada en la Figura 6.3, evidencia picos transitorios severos que superan magnitudes del orden de 10^4 . Esta observación empírica justifica con rigor la necesidad técnica de emplear recorte de gradientes (*gradient clipping*) dentro de Ranger21, mecanismo que resultó determinante para absorber inestabilidades locales y prevenir colapso numérico en los tensores durante fases críticas del aprendizaje.




Figura 6.3: Evolución de la norma del gradiente en escala logarítmica durante el entrenamiento.

6.2 Evaluación

La validación cuantitativa del sistema se ha llevado a cabo sobre el subconjunto de test, compuesto por 40.000 muestras correspondientes a recintos no observados durante la fase de optimización. Para la inferencia se ha empleado el punto de control óptimo (*checkpoint*) extraído en la época 540. El rendimiento se cuantifica mediante una doble perspectiva: por un lado, la fidelidad espectral global de la respuesta sintetizada y, por otro, la consistencia de descriptores acústicos físicos derivados de la Curva de Decaimiento de Energía (EDF).

Listing 6.1: Ejecución de la evaluación cuantitativa sobre el conjunto de test/validación.

```
CHECKPOINT_FINAL="/content/drive/MyDrive/TFG_Checkpoints/decor_v5_FINAL_ORO.pth"
DATA_LOCAL="/content/BIRD_Local"
python scripts/eval.py \
    --checkpoint "$CHECKPOINT_FINAL" \
    --data-root "$DATA_LOCAL"
```

Tal como se resume en la Tabla 6.1, el error MSTFT de 8.6108 cuantifica la fidelidad global de la distribución de energía espectrogramática y refleja una correspondencia robusta entre las envolventes espectro-temporales de referencia y las extrapoladas. De forma complementaria, los valores de EDF MAE (5.39 dB) y EDF RMSE (7.26 dB) evidencian un desajuste reducido en la pendiente de la cola reverberante en escala logarítmica, resultado que respalda una coherencia energética de alta precisión en la representación del decaimiento tardío.

Métrica	Valor Medio (μ)
Error Espectral Multiresolución (MSTFT)	8.6108
Error Absoluto Medio de la EDF (EDF MAE) [dB]	5.39
Raíz del Error Cuadrático Medio de la EDF (EDF RMSE) [dB]	7.26
Error Porcentual Absoluto Medio del T_{60} (T_{60} MAPE) [%]	8.1
Error Cuadrático Medio de la Relación Directo-Reverberante (DRR MSE) [dB]	7.24

Tabla 6.1: Métricas de evaluación objetiva sobre el conjunto de test. Se reportan los valores medios obtenidos tras procesar las 40.000 muestras de evaluación.

En el plano de descriptores macroscópicos, el rendimiento alcanzado mantiene un nivel sobresaliente desde la perspectiva arquitectónica del sistema. El Error Porcentual Absoluto Medio del tiempo de reverberación, expresado como T_{60} MAPE, se asienta en 8.1%, y un margen confinado a un único dígito constituye evidencia empírica de que el decodificador infiere de forma correcta el volumen efectivo y la absorción equivalente de la sala. Finalmente, el DRR MSE de 7.24 dB constata la preservación del balance energético entre el campo acústico directo y el campo difuso, reforzando la validez física de las respuestas impulsionales reconstruidas.

La comparación con modelos de referencia, sintetizada en la Tabla 6.2, permite situar el comportamiento del sistema en un marco competitivo. En dicha tabla, la métrica MSTFT se marca con flecha ascendente ($\uparrow$) para señalar de forma explícita que, en este contraste concreto, el valor del modelo propuesto resulta superior al de Naive y FiNS, es decir, no constituye su punto fuerte cuando se analiza únicamente el error espectral agregado. No obstante, el modelo propuesto exhibe mejoras sustanciales en los descriptores energéticos y macroscópicos de interés acústico, particularmente en EDF MAE, EDF RMSE, T_{60} MAPE y DRR MSE. Este patrón respalda que la arquitectura está orientada a preservar con mayor fidelidad la estructura física del decaimiento reverberante y el balance energético global de la sala, objetivos centrales del presente trabajo.

Modelo	MSTFT ($\uparrow$)	EDF (MAE, dB, $\downarrow$)	EDF (RMSE, dB, $\downarrow$)	T_{60} (MAPE, %, $\downarrow$)	DRR (MSE, dB, $\downarrow$)
DECOR (propuesto)	8.6108	5.39	7.26	8.1	7.24
Naive	3.53	12.8	17.3	41.6	14.5
FiNS	1.32	10.9	13.9	41.9	8.68

Tabla 6.2: Comparativa con modelos de referencia en métricas objetivas. En MSTFT se emplea flecha ascendente ($\uparrow$) para destacar que el valor del modelo propuesto es mayor que el de las referencias; en el resto de métricas, flecha descendente ($\downarrow$) indica mejor rendimiento para valores menores.

6.3 Caso cualitativo

Con el propósito de interpretar el comportamiento del modelo más allá de las métricas numéricas agregadas, se examina cualitativamente un caso de estudio extraído del subconjunto de evaluación. Este análisis permite inspeccionar de forma directa la correspondencia entre señal de referencia y señal extrapolada en tres planos complementarios: la forma de onda temporal, la distribución espectro-temporal de energía y la dinámica de decaimiento energético acumulado.




Figura 6.4: Evaluación cualitativa de un caso de estudio. (Arriba) Comparativa de la forma de onda temporal. (Centro) Espectrogramas de magnitud. (Abajo) Curvas de Decaimiento de Energía (EDC).

Tal como se observa en la Figura 6.4, la comparación de la forma de onda temporal puede sintetizarse en los siguientes puntos:

Aciertos del modelo

- **Envoltente de decaimiento.** DECOR reproduce con elevada fidelidad la estructura macro-

temporal de la reverberación. La atenuación progresiva de la amplitud a lo largo del tiempo, asociada a la cola reverberante, resulta prácticamente coincidente con la respuesta real.

- **Densidad de la cola reverberante.** A partir del régimen de campo difuso (aproximadamente desde 200 ms), la síntesis mantiene un patrón denso y estocástico coherente con la señal de referencia, convergiendo hacia niveles próximos a cero en un horizonte temporal equivalente.

Puntos de mejora y limitaciones

- **Subestimación de amplitud máxima.** La discrepancia más visible aparece en los picos iniciales: la señal real alcanza máximos superiores (del orden de 0.3), mientras que la señal estimada presenta picos más contenidos (en torno a 0.2), lo que equivale a una respuesta parcialmente atenuada en escala lineal.
- **Pérdida de estructura fina en reflexiones tempranas.** En el intervalo inicial (aproximadamente 0–100 ms), la respuesta real presenta reflexiones tempranas discretas y bien separadas. La predicción conserva su localización global, pero las representa con mayor aglomeración y menor varianza local, reduciendo nitidez en el detalle microscópico de la onda.

En el dominio espectral, la lectura de la Figura 6.4 puede sintetizarse en los siguientes aspectos:

Aciertos del modelo

- **Envolvente macro y distribución de energía.** La predicción preserva la estructura global del espectrograma, reproduciendo con fidelidad tanto el impacto energético inicial como el decaimiento progresivo en el eje temporal.
- **Decaimiento dependiente de la frecuencia.** Se mantiene un comportamiento físicamente coherente: las componentes de alta frecuencia se extinguen antes, mientras que las bandas bajas y medias conservan energía durante intervalos más prolongados.
- **Alineación temporal del decaimiento.** El instante de agotamiento energético global se sitúa en un entorno temporal concordante con la referencia, lo que respalda una estimación consistente del tiempo reverberante efectivo.

Puntos de mejora y limitaciones

- **Efecto de suavizado.** La síntesis presenta una textura más difuminada que la señal medida, cuya microestructura estocástica resulta más rugosa en la cola tardía.
- **Resolución modal en bajas frecuencias.** En la banda baja (aproximadamente 0–128 Hz), las trazas modales verticales se representan con menor nitidez y mayor cuantización espacial.

- **Atenuación del fondo residual.** En el tramo final del decaimiento, la predicción tiende a suprimir con mayor intensidad el ruido de fondo tenue observado en la referencia.

La comparación de las curvas EDC, igualmente visible en la Figura 6.4, puede resumirse del siguiente modo:

Aciertos del modelo

- **Seguimiento de la tendencia global.** Durante la mayor parte del eje temporal, la curva estimada se superpone de forma casi idéntica a la curva de referencia, reflejando una estimación precisa de la distribución energética macroscópica.
- **Estabilidad sin desviaciones sistémicas.** No se observan saltos espurios, oscilaciones anómalas ni desplazamientos persistentes de nivel entre trayectorias, lo que indica normalización energética robusta.

Puntos de mejora y limitaciones

- **Divergencia en el truncamiento final.** En el entorno previo a la caída abrupta al suelo de ruido, la predicción tiende a retener energía ligeramente más tiempo o a decaer de forma menos brusca que la referencia.
- **Sensibilidad al ruido de fondo estocástico.** La estimación del instante exacto de corte en la cola final mantiene una dificultad intrínseca elevada en modelos neuronales aplicados a audio.

En conjunto, pese a las discrepancias localizadas en la microtextura espectral y en el truncamiento final, la coincidencia global de patrones respalda que el sistema asimila con elevada precisión la dinámica energética del recinto y confirma su robustez matemática en extrapolación ciega.

Capítulo 7

Conclusiones y Trabajo Futuro

7.1 Conclusiones

El presente Trabajo de Fin de Grado ha resuelto de forma satisfactoria el problema de la extrapolación de la respuesta al impulso tardía a partir de una observación parcial de 50 ms. La evidencia experimental obtenida confirma que la información contenida en el tramo temprano, cuando se procesa mediante una arquitectura físicamente informada, resulta suficiente para reconstruir con consistencia la dinámica energética de la cola reverberante en recintos no observados durante el aprendizaje.

El balance crítico de resultados permite establecer una conclusión de fondo: la arquitectura paramétrica propuesta, DECOR, demuestra que el Procesamiento de Señal Diferenciable (DDSP) introduce un sesgo inductivo termodinámico esencial para el problema abordado. Aunque enfoques puramente generativos del estado del arte pueden optimizar con mayor facilidad distancias espectrales agregadas como MSTFT, su comportamiento evidencia limitaciones estructurales al representar magnitudes físicas del recinto. En contraste, alcanzar un error del 8.1% en la estimación de T_{60} y preservar de manera robusta la Curva de Decaimiento de Energía (EDC) valida la hipótesis central del proyecto: en extrapolación de reverberación tardía, la coherencia acústica constituye un criterio de mayor relevancia que la similitud espectrogramática cruda.

Desde una perspectiva metodológica, también se han consolidado aportaciones de carácter transversal. La estabilización de gradientes mediante técnicas de recorte (*gradient clipping*), junto con una estrategia de aprendizaje por currículo, resultó determinante para alcanzar convergencia en una superficie de pérdida marcadamente no convexa. Esta combinación permitió absorber transitorios de alta inestabilidad durante las fases de acoplamiento físico de la función de coste y condujo a un

régimen final de optimización estable, reproducible y físicamente interpretable.

7.2 Trabajo futuro

Como primera línea de investigación, se propone abordar de forma explícita la síntesis de microestructura estocástica de la cola reverberante, aspecto donde el análisis cualitativo ha identificado limitaciones en factor de cresta y rugosidad fina. Una vía prometedora consiste en acoplar modelos generativos complementarios, tales como Redes Adversarias Generativas o Modelos de Difusión, condicionados por los parámetros físicos estimados por el bloque DDSP. Este esquema híbrido permitiría recuperar detalle microscópico sin comprometer la envolvente macroscópica ni la consistencia energética global.

De forma complementaria, se considera especialmente relevante explorar la extrapolación directa mediante arquitecturas Transformer. Su mecanismo de autoatención podría capturar dependencias temporales de largo alcance entre reflexiones tempranas y cola reverberante, permitiendo modelar con mayor flexibilidad la evolución espectro-temporal sin perder coherencia física cuando se incorporen restricciones acústicas en la función objetivo.

Una segunda línea prioritaria se orienta a la expansión espacial y multicanal del marco actual. En particular, la adaptación a representaciones inmersivas tridimensionales, como Ambisonics o formulaciones basadas en HRTF, abriría la posibilidad de extrapolar no solo la evolución temporal de la energía, sino también la direccionalidad del campo difuso. Esta extensión incrementaría de forma sustancial el alcance aplicado del método en escenarios de Realidad Virtual, auralización interactiva y reproducción espacial avanzada.

Finalmente, se propone profundizar en la optimización de inferencia con el objetivo de viabilizar su despliegue en tiempo real. Entre las estrategias más relevantes se encuentran la destilación del modelo hacia arquitecturas de menor coste computacional y la traslación de componentes críticos a implementaciones de bajo nivel. Este esfuerzo permitiría aproximar el uso de DECOR a plataformas embebidas y sistemas con restricciones estrictas de latencia, favoreciendo su transferencia efectiva a entornos de producción.

Presupuesto y viabilidad económica

7.3 Costes

Para una estimación simple y coherente, se ha considerado un periodo de trabajo de febrero a junio (aprox. 21 semanas) con una dedicación media de 20 horas semanales del estudiante.

Hipótesis utilizadas:

- Horas de estudiante: $21 \times 20 = 420$ h.
- Coste hora estudiante (ingeniero pre-júnior): 18 EUR/h.
- Dedicación de dirección académica (profesor): 40 h totales.
- Coste hora profesor (UPC Terrassa): 70 EUR/h.
- Google Colab Pro: 100 unidades informáticas con coste total de 10 EUR.

Tabla 7.1: Resumen de costes del TFG (estimación simple)

Concepto	Horas / unid.	Coste unitario	Coste total
Estudiante (ingeniero pre-júnior)	420 h	18 EUR/h	7.560 EUR
Profesor (dirección y seguimiento)	40 h	70 EUR/h	2.800 EUR
Google Colab Pro	100 unidades informáticas	0,10 EUR/unidad	10 EUR
Total estimado			10.370 EUR

Esta estimación debe considerarse orientativa y sin impuestos indirectos, y resulta útil para valorar la viabilidad económica del desarrollo en un contexto académico.

Impacto ambiental y social

El desarrollo de modelos de aprendizaje profundo para audio inmersivo no puede evaluarse de forma completa si se omite su dimensión energética. En el presente trabajo, el uso de aceleradores gráficos (GPU) de altas prestaciones ha sido una condición técnica necesaria para entrenar secuencias largas de señal acústica con estabilidad numérica y en tiempos razonables. Sin embargo, esta decisión metodológica conlleva un coste ambiental asociado al consumo eléctrico intensivo durante las fases de optimización.

Desde una perspectiva cuantitativa, la energía consumida durante entrenamiento puede aproximarse por

$$E \approx P_{med} \cdot T, \quad (7.1)$$

donde P_{med} representa la potencia media efectiva del sistema de cómputo y T el tiempo total de uso. A su vez, la huella de carbono operativa puede estimarse como

$$\text{CO}_2\text{eq} \approx E \cdot I_{red}, \quad (7.2)$$

siendo I_{red} la intensidad de carbono de la red eléctrica que alimenta la infraestructura. Este marco evidencia que la eficiencia algorítmica no es únicamente una cuestión de rendimiento computacional, sino también un criterio de responsabilidad ambiental.

Bajo este enfoque, la arquitectura DECOR aporta una ventaja relevante: al introducir sesgo físico mediante DDSF y reducir dimensionalidad efectiva de la síntesis, permite alcanzar objetivos acústicos robustos con complejidad inferior a alternativas puramente generativas de mayor escala. En términos prácticos, una reducción de parámetros, épocas efectivas o tiempo de convergencia se traduce en menor demanda energética por experimento y, por extensión, en menor impacto ambiental acumulado en ciclos iterativos de investigación.

La reflexión social del proyecto se articula en dos planos. Primero, en el plano de acceso tecnológico, el alto coste de entrenamiento sobre GPU de gama alta puede ampliar la brecha entre grupos con distinta capacidad de cómputo. En consecuencia, el diseño de modelos más eficientes constituye también una estrategia de democratización científica. Segundo, en el plano aplicado, la capacidad de extrapolar reverberación realista con menor coste abre oportunidades en educación, accesibilidad y producción audiovisual, al facilitar herramientas acústicas avanzadas en contextos con recursos limitados.

Como criterio de buena práctica, se propone consolidar en trabajos futuros una política de cómputo responsable: monitorización explícita de consumo energético por experimento, reutilización sistemática de *checkpoints*, priorización de búsquedas de hiperparámetros de bajo coste y reporte transparente de métricas de eficiencia junto a las métricas de precisión acústica. Este enfoque permite alinear rigor científico, sostenibilidad ambiental e impacto social positivo en el desarrollo de sistemas de inteligencia artificial para acústica computacional.

Bibliography

- [AB79] Jont B Allen and David A Berkley. “Image method for efficiently simulating small-room acoustics”. In: *The Journal of the Acoustical Society of America* 65.4 (1979), pp. 943–950.
- [Eng+20] Jesse Engel et al. “DDSP: Differentiable Digital Signal Processing”. In: *International Conference on Learning Representations*. 2020.
- [GBC16] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT press, 2016.
- [Gro+20] François Grondin et al. “BIRD: Big Impulse Response Dataset”. In: *ArXiv abs/2010.09930* (2020). URL: <https://api.semanticscholar.org/CorpusID:224803038>.
- [Kar+24a] Xenofon Karakonstantis et al. *RIRPINN*. 2024. URL: <https://github.com/xefonon/RIRPINN>.
- [Kar+24b] Xenofon Karakonstantis et al. “Room impulse response reconstruction with physics-informed deep learning”. In: *The Journal of the Acoustical Society of America* 155.2 (Feb. 2024), pp. 1048–1059. ISSN: 0001-4966. DOI: [10.1121/10.0024750](https://doi.org/10.1121/10.0024750). eprint: https://pubs.aip.org/asa/jasa/article-pdf/155/2/1048/19508065/1048_1_10.0024750.pdf. URL: <https://doi.org/10.1121/10.0024750>.
- [Kut16] Heinrich Kuttruff. *Room Acoustics*. 6th. CRC Press, 2016.
- [LGS25] Jackie Lin, Georg Götz, and Sebastian Schlecht. “Deep room impulse response completion”. In: *EURASIP Journal on Audio, Speech, and Music Processing* 2025 (May 2025), p. 20. DOI: [10.1186/s13636-024-00383-1](https://doi.org/10.1186/s13636-024-00383-1).
- [MS25] Imran Muhammad and Gerald Schuller. *Room Impulse Response Prediction with Neural Networks: From Energy Decay Curves to Perceptual Validation*. 2025. arXiv: [2509.24834](https://arxiv.org/abs/2509.24834) [eess.AS]. URL: <https://arxiv.org/abs/2509.24834>.
- [Sch65] Manfred R Schroeder. “New method of measuring reverberation time”. In: *The Journal of the Acoustical Society of America* 37.3 (1965), pp. 409–412.